Deep Learning par la Pratique

Apprentissage d'un Réseau de Neurones

Rappel

Les données en entrée doivent être normalisées :

$$X_{norm} = \frac{X - mean(X_{train})}{std(X_{train})}$$

Rappel

1 - initialisation **aléatoire** du modèle
2 - Tant que(critère arret $==$ 0)

- Selection aléatoire d'un **batch** de données
- **Forward** : Passe avant du **batch** dans le modèle
- Calcul de l'erreur par rapport aux sorties attendues
- **Backward** : Rétropropagation du gradient de l'erreur en fonction des paramètres dans le modèle (mise à jour du modèle)
- Calcul critère arret

3 - Calcul de l'erreur sur un échantillon de données **qui n'ont JAMAIS été vues par le modèle pendant l'apprentissage !**

Quelle fonction de perte (Loss) choisir ?

Fonction de perte (Loss function)

Exemple facile : “Prédire la température demain”

Erreur $= T_{pred} - T_{real}$

Fonction de perte (Loss function)

Exemple difficile : “Prédire la catégorie d’une image”

$\approx$ Distance entre la sortie et la cible

Sortie :

0.0	0.1	0.4	0.0	0.0	0.2	0.1	0.0	0.2	0.0

Cible :

0.0	0.0	**1.0**	0.0	0.0	0.0	0.0	0.0	0.0	0.0

Fonction de perte (Loss function)

Calcul du gradient de l'erreur par rapport aux paramètres :

$$grad_i = \frac{\partial Err}{\partial w_i}$$

Mise à jour :

$$w_i' = w_i - \gamma * grad_i$$

où : $0 < \gamma < 1$ (learning rate)

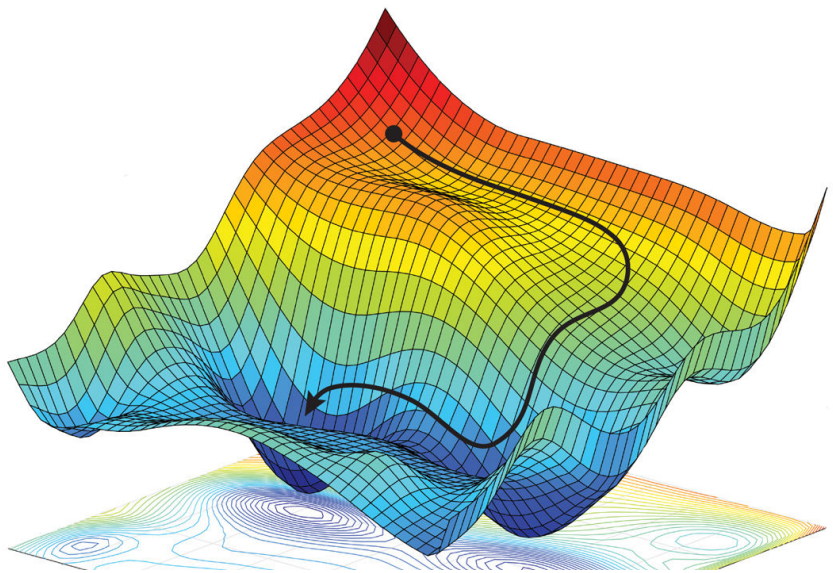

Fonction de perte (Loss function)

Regression Loss Functions :

- Erreur **absolue**
- Erreur **lissée**
- ...

Classification Loss Functions :

- Entropies-croisées
- Log vraisemblance
- Loss à marge
- ...

Embedding Loss Functions :

- L1(,L2,...)
- Distance cosinus
- ...

Gradient et mise à jour

Exemple de descente de gradient sur un cas simple : la regression

- $y = a.X + b$
- $\mathrm{L} = \frac{1}{2n} \sum_{i=[1..n]} (y_i^* - y_i)^2$
- $\mathrm{L} = \frac{1}{2n} \sum_{i=[1..n]} (y_i^* - (a.x_i + b))^2$
- ...
- $\frac{\partial L}{\partial a} = \frac{1}{n} \sum_{i=[1..n]} (a.X + b - y^*).X$
- $\frac{\partial L}{\partial b} = \frac{1}{n} \sum_{i=[1..n]} (a.X + b - y^*)$

M.A.J :

- $a = a - \gamma \frac{\partial L}{\partial a}$
- $b = b - \gamma \frac{\partial L}{\partial b}$
- où $1 > \gamma > 0$ (learning rate)

Gradient et mise à jour

initialisation au hasard ($\gamma = 0.01$)

- a $= 0.58$ ($\hat{a} = 3.0$)
- b $= 0.25$ ($\hat{b} = 0.5$)

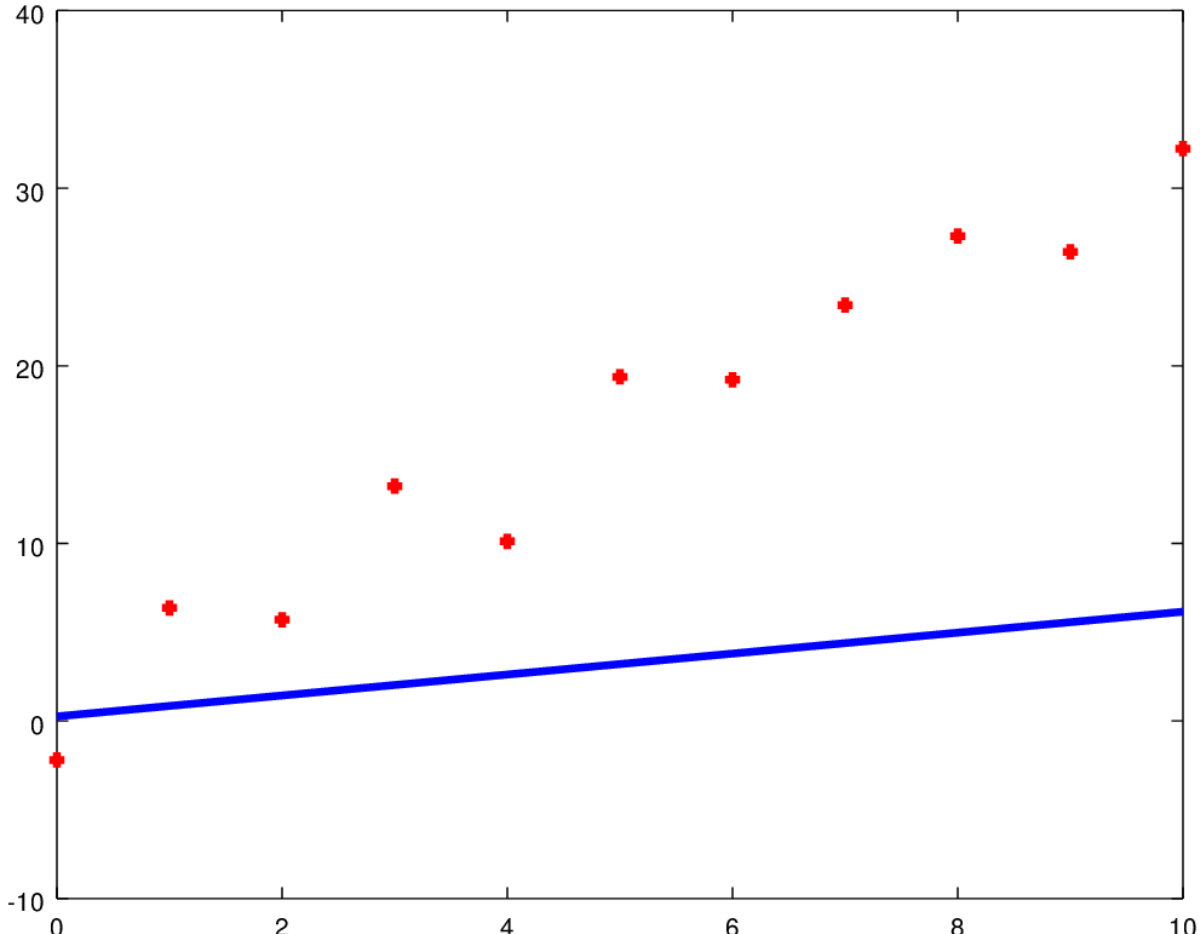

Gradient et mise à jour

- a $= 0.58$ ($\hat{a} = 3.0$)
- b $= 0.25$ ($\hat{b} = 0.5$)

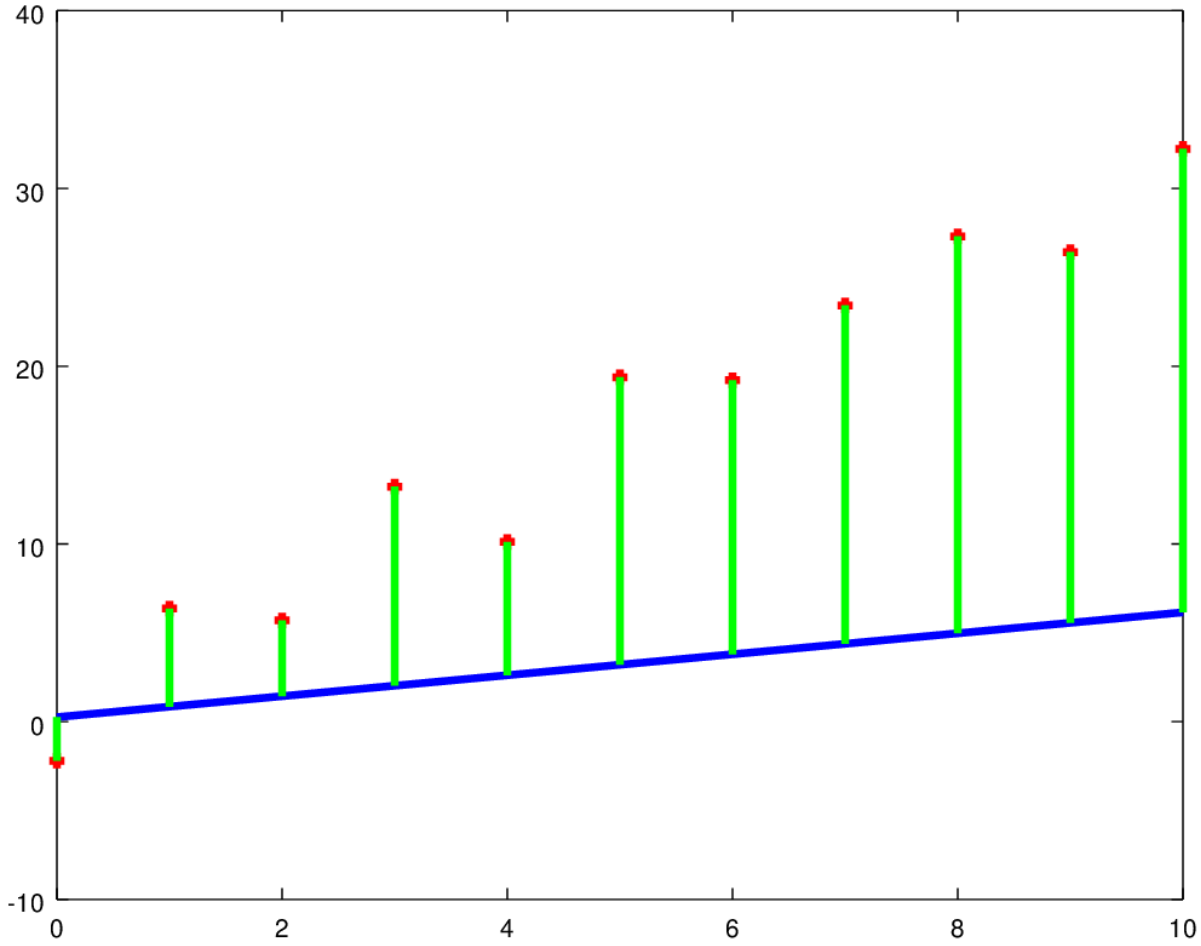

Gradient et mise à jour

- a $= 1.50$ ($\hat{a} = 3.0$)
- b $= 0.35$ ($\hat{b} = 0.5$)

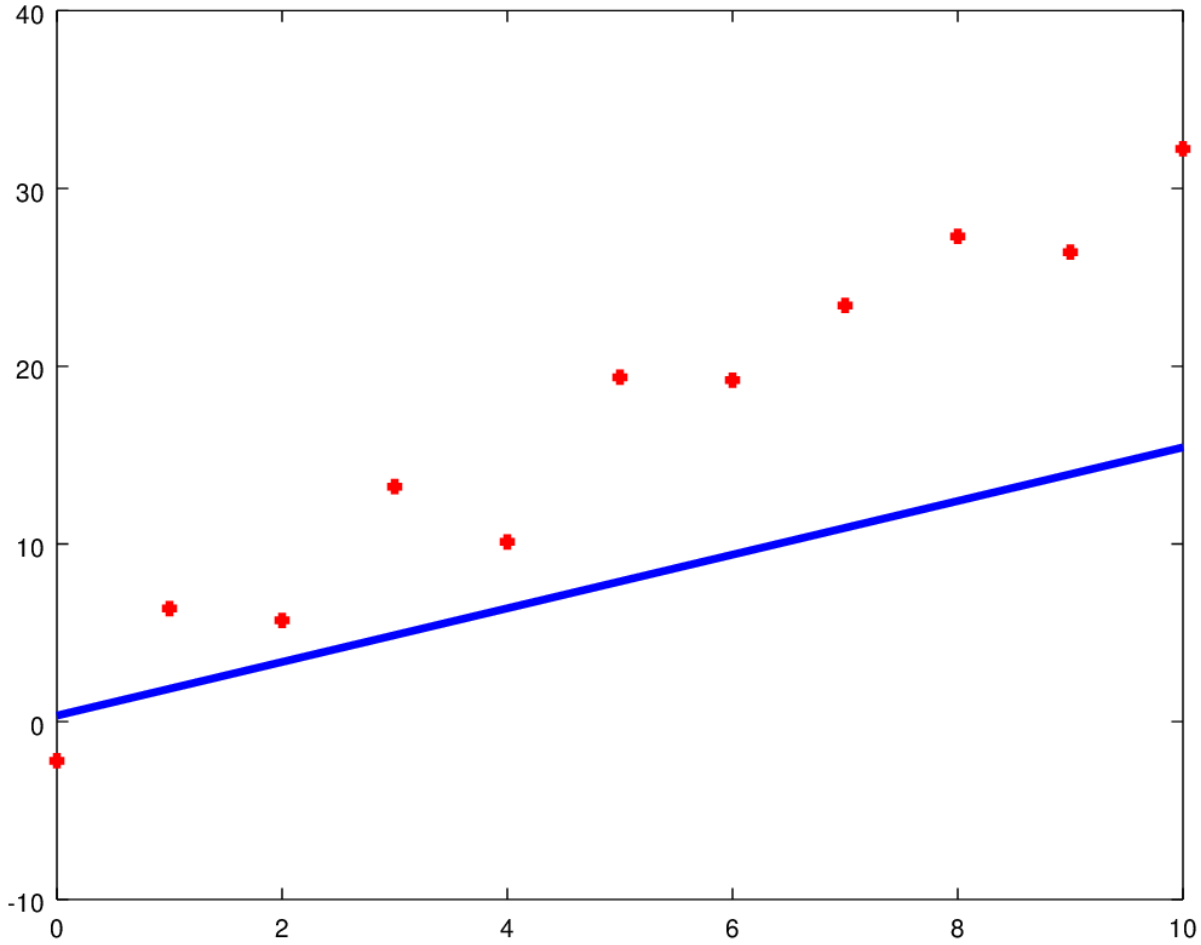

Gradient et mise à jour

- a $= 2.10$ ($\hat{a} = 3.0$)
- b $= 0.40$ ($\hat{b} = 0.5$)

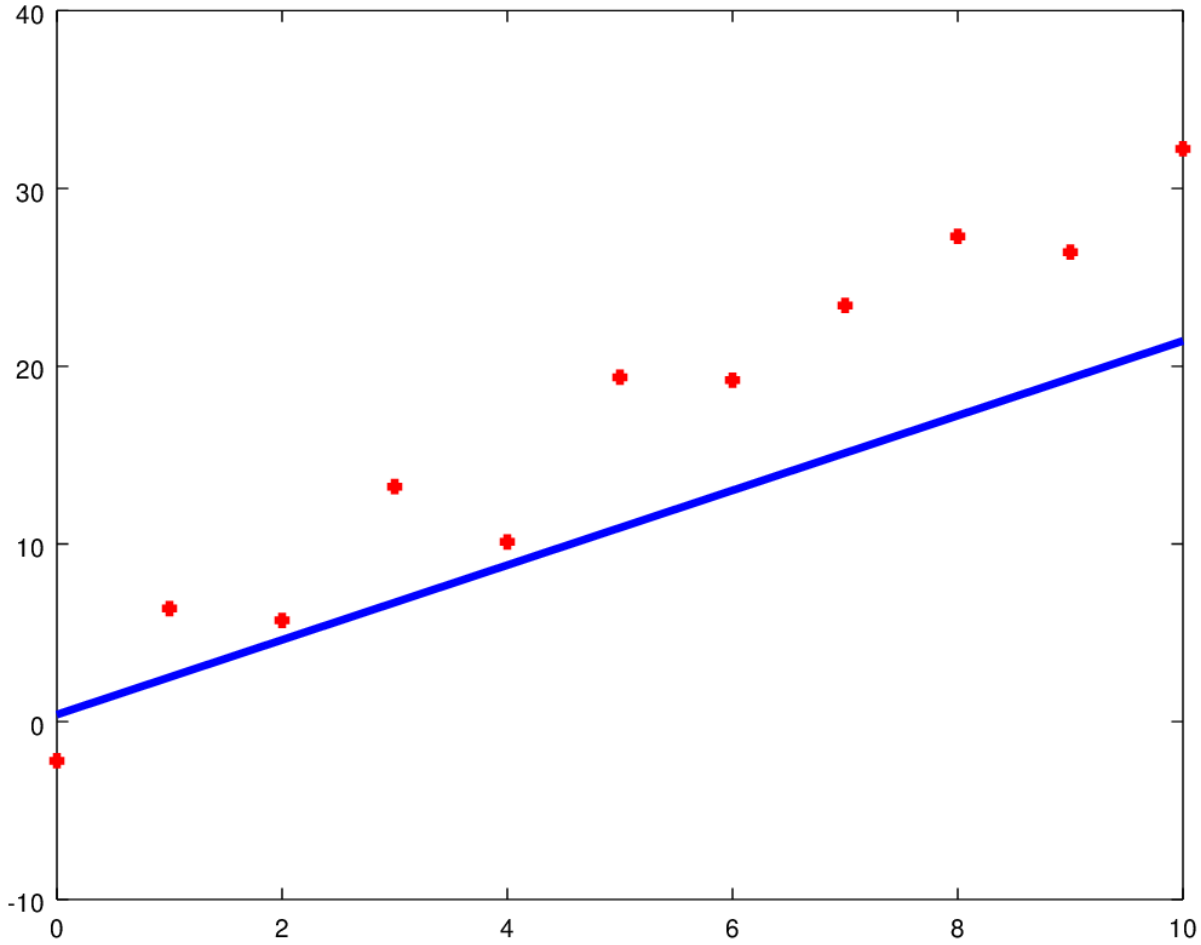

Gradient et mise à jour

- a $= 2.48$ ($\hat{a} = 3.0$)
- b $= 0.43$ ($\hat{b} = 0.5$)

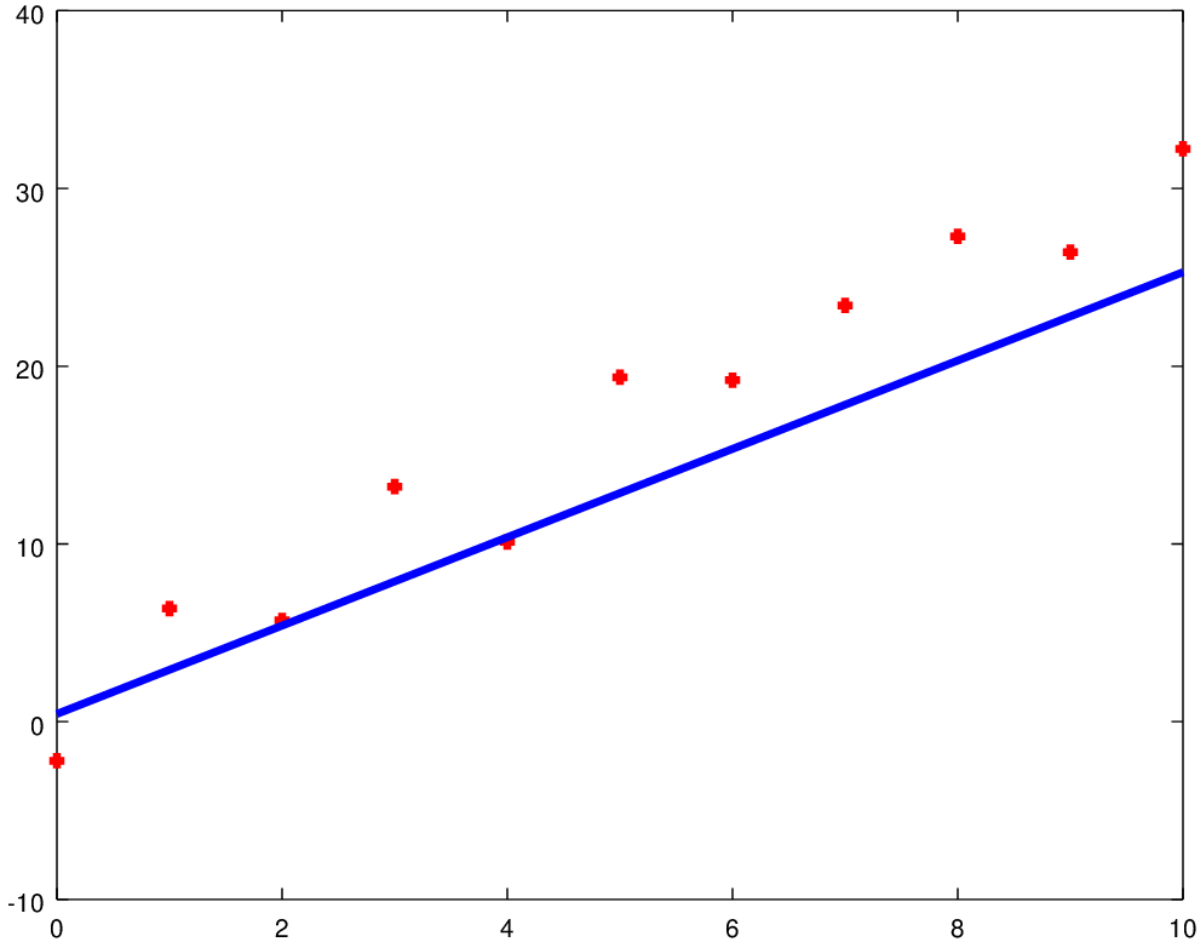

Gradient et mise à jour

- a $= 2.73$ ($\hat{a} = 3.0$)
- b $= 0.46$ ($\hat{b} = 0.5$)

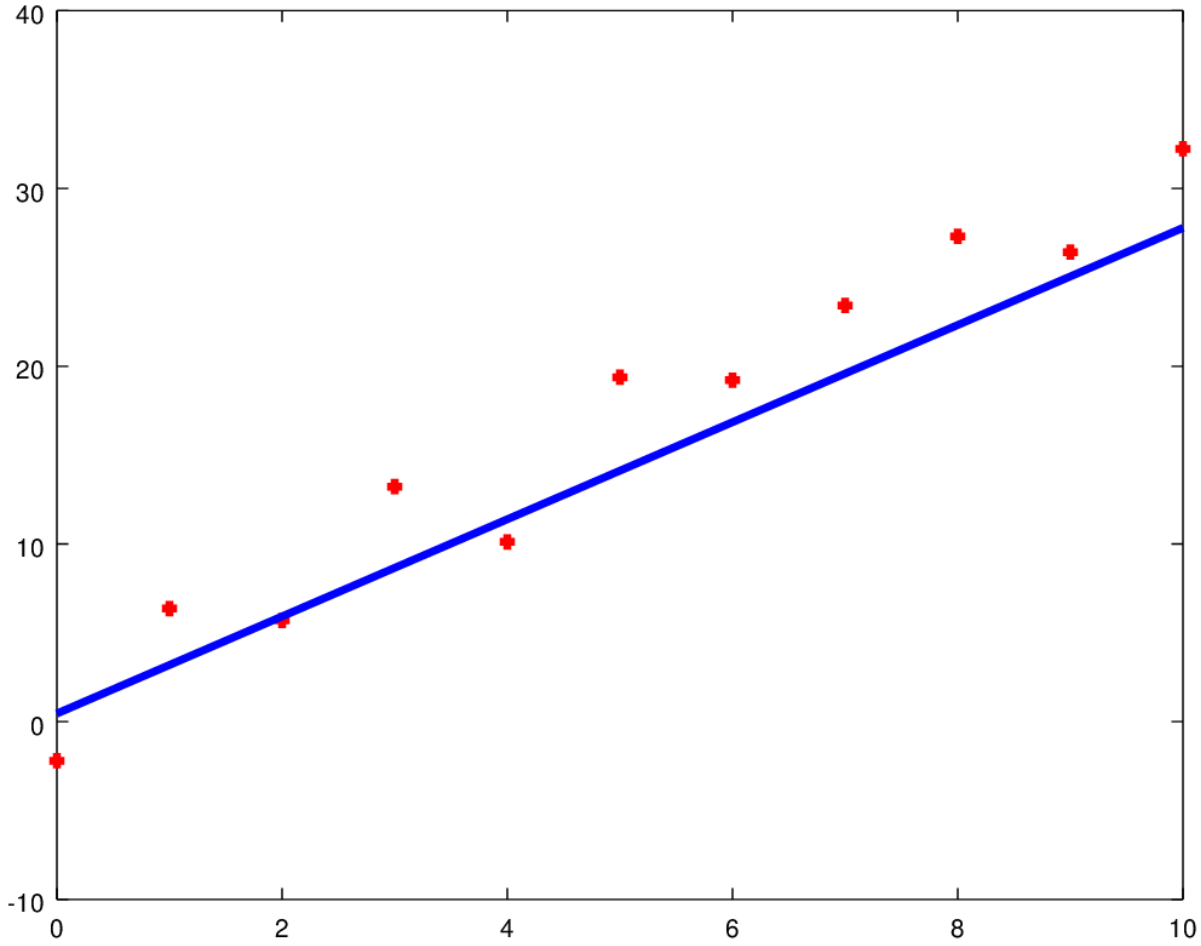

Gradient et mise à jour

- a $= 2.89$ ($\hat{a} = 3.0$)
- b $= 0.47$ ($\hat{b} = 0.5$)

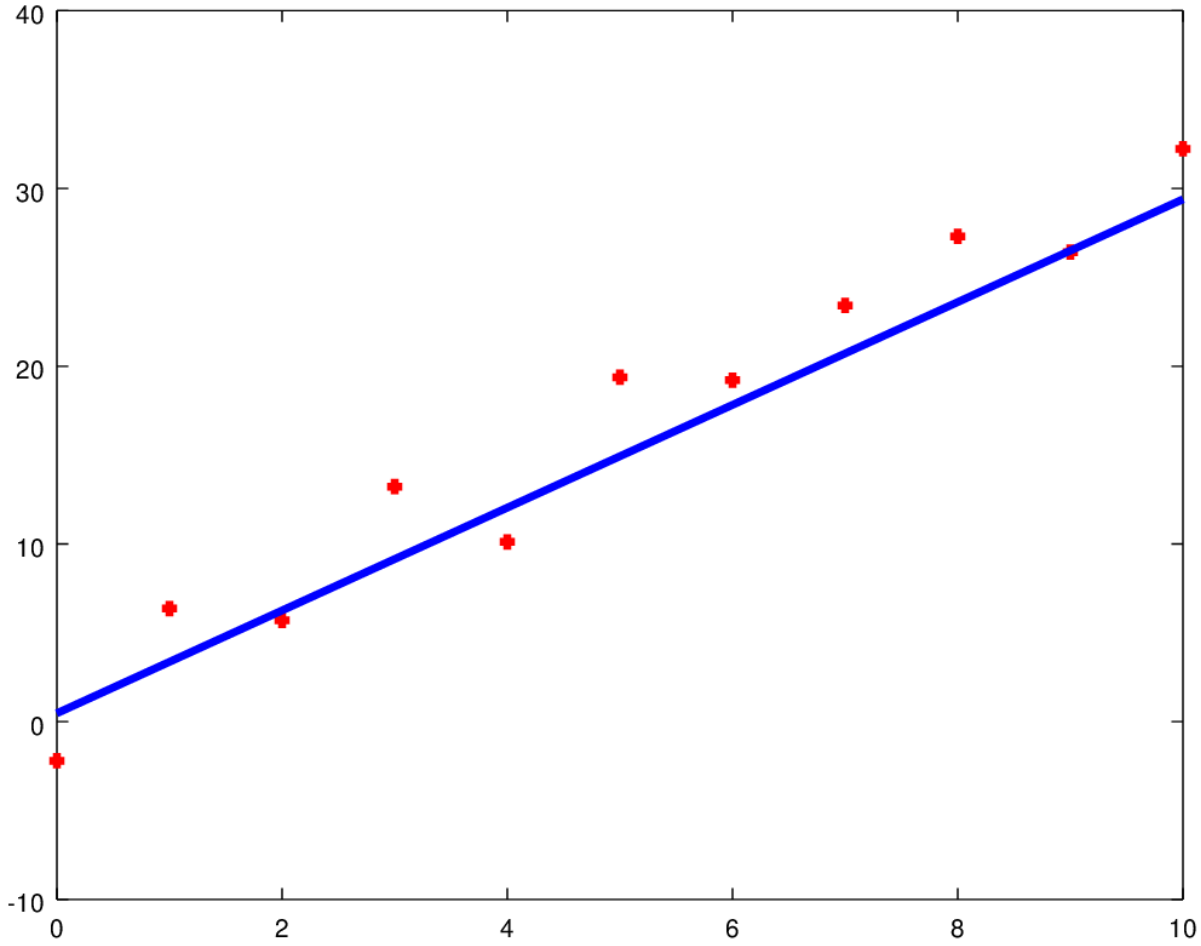

Gradient et mise à jour

- a $= 2.99$ ($\hat{a} = 3.0$)
- b $= 0.48$ ($\hat{b} = 0.5$)

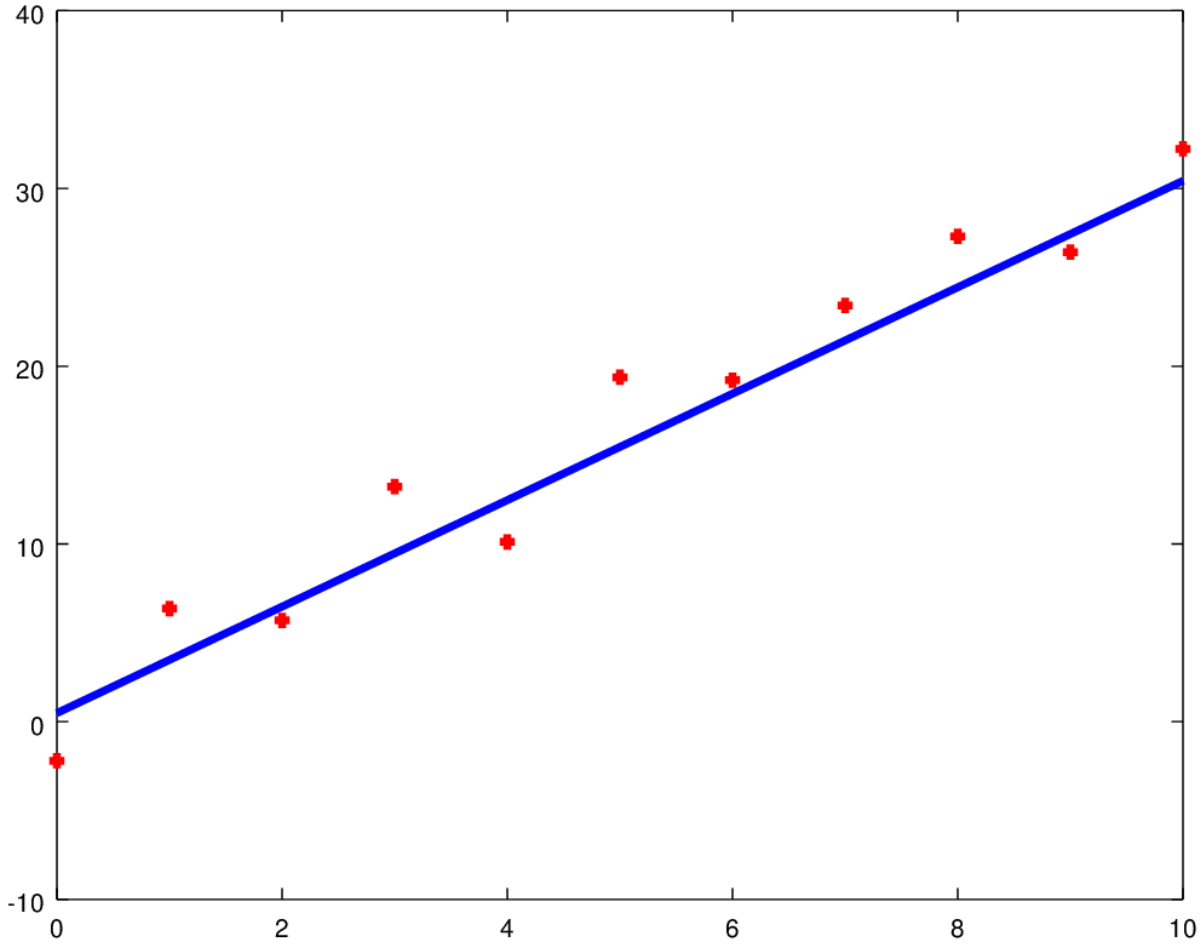

Gradient et mise à jour

- a $= 3.06$ ($\hat{a} = 3.0$)
- b $= 0.49$ ($\hat{b} = 0.5$)

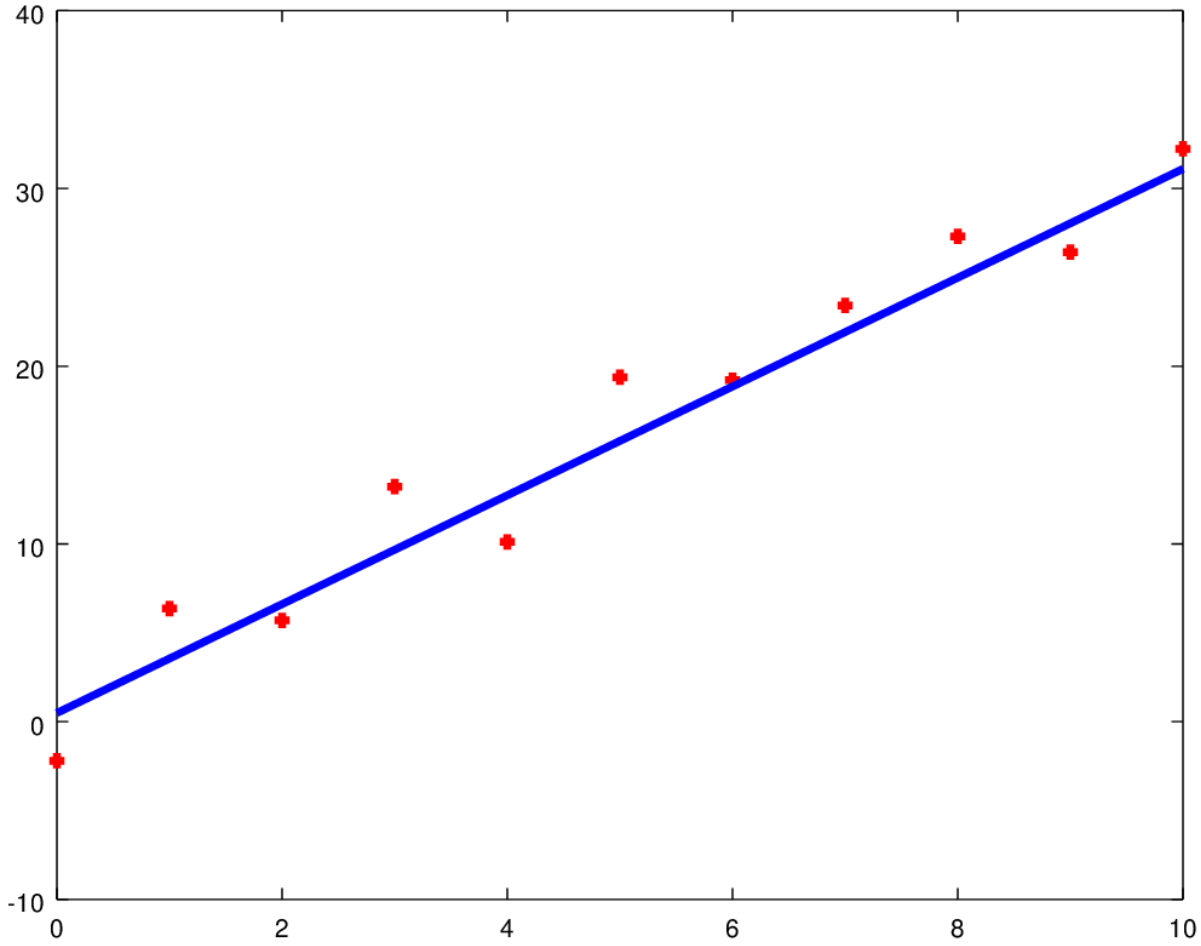

Gradient et mise à jour

- a $= 3.10$ ($\hat{a} = 3.0$)
- b $= 0.49$ ($\hat{b} = 0.5$)

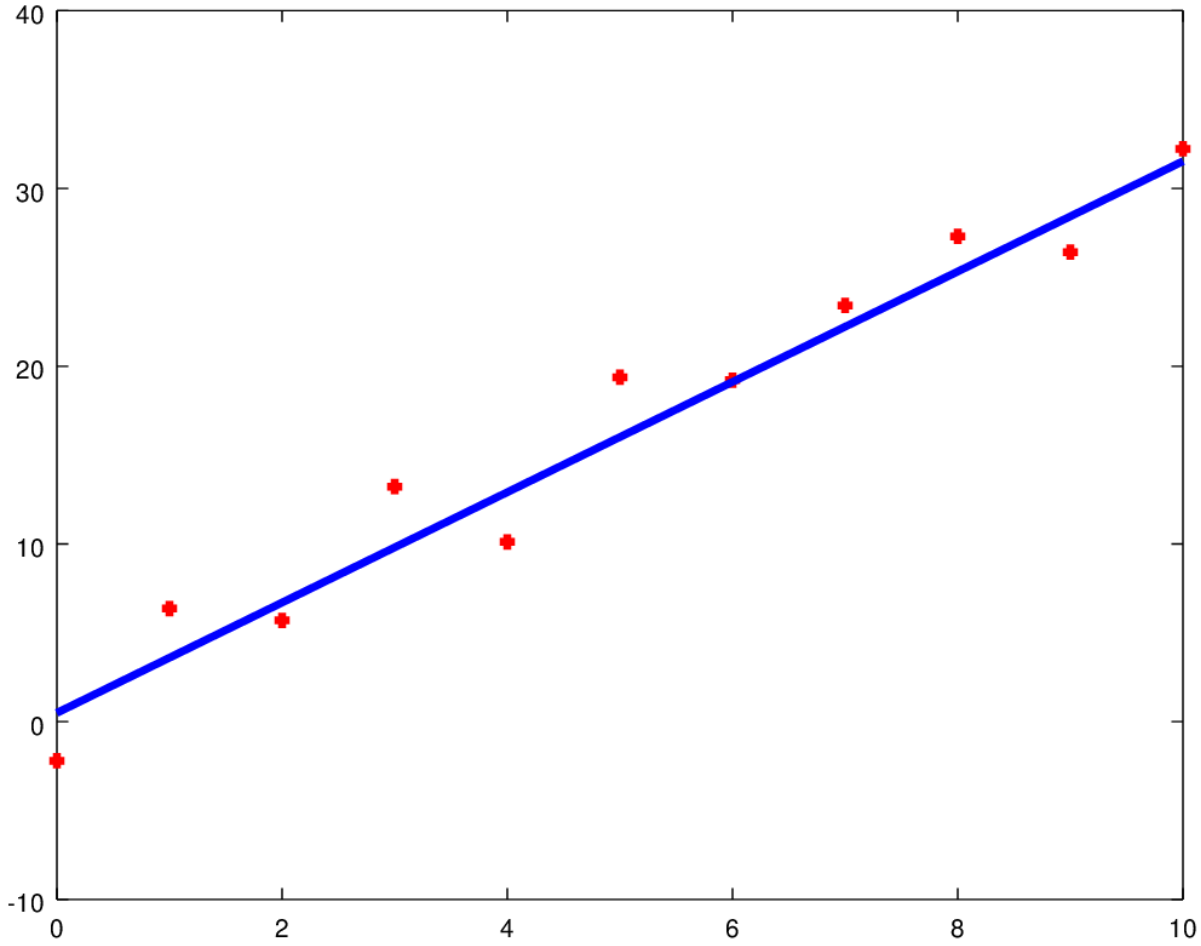

Gradient et mise à jour

- a $= 3.13$ ($\hat{a} = 3.0$)
- b $= 0.50$ ($\hat{b} = 0.5$)

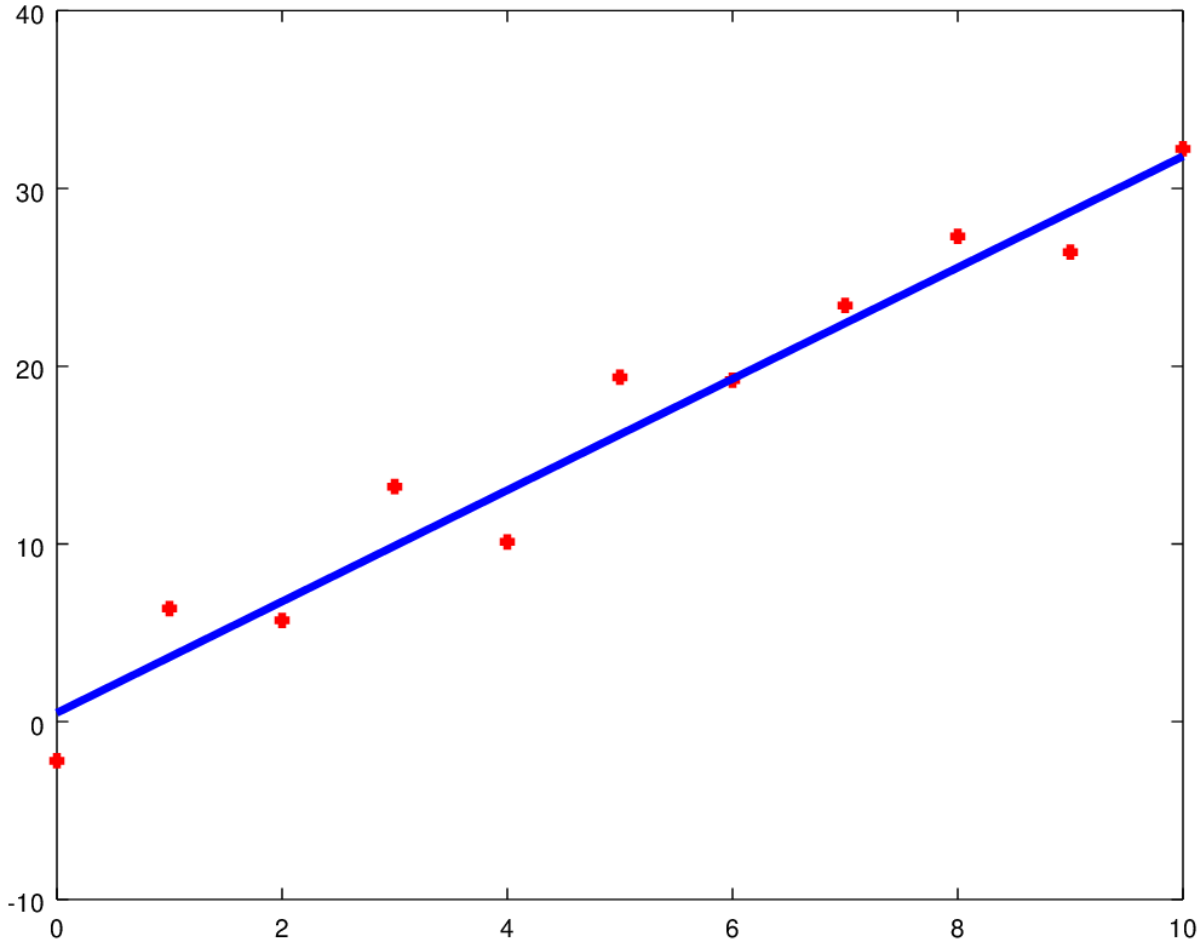

Convergence

Convergence du modèle vers l'optimal ?

Convergence

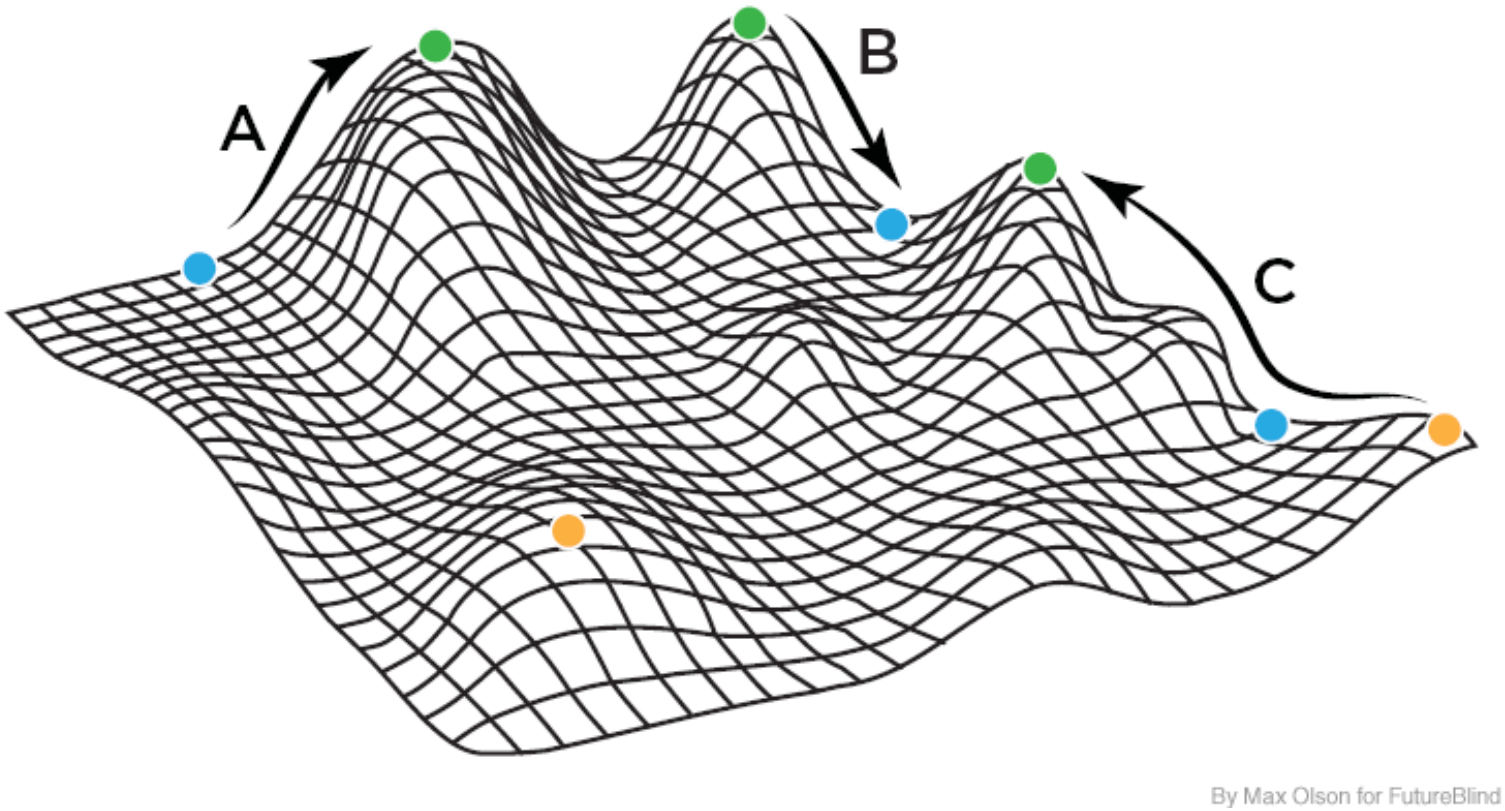

Convergence

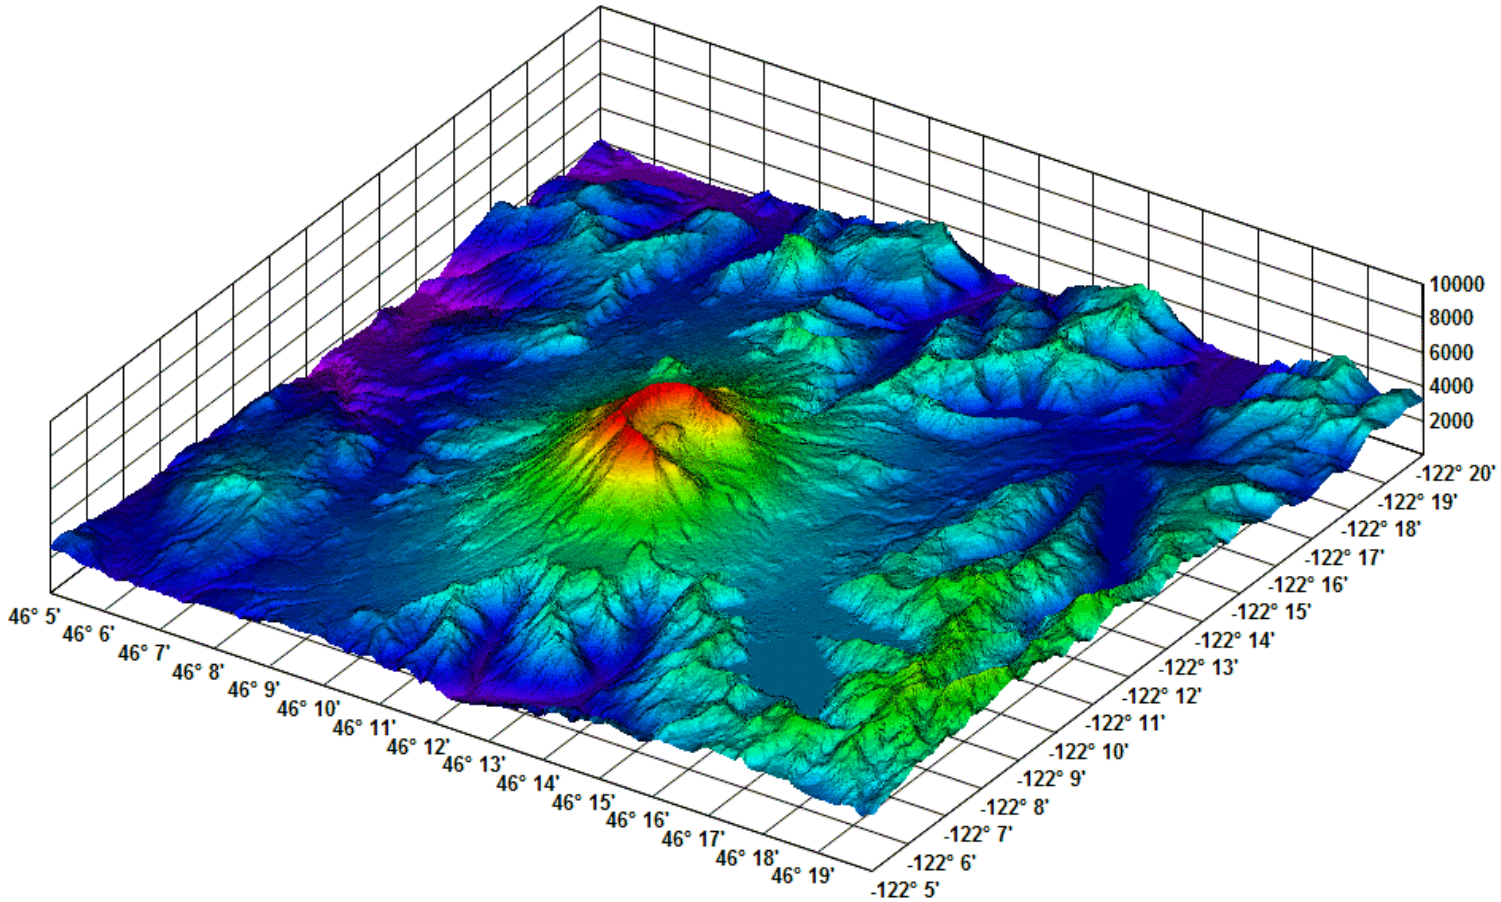

Convergence

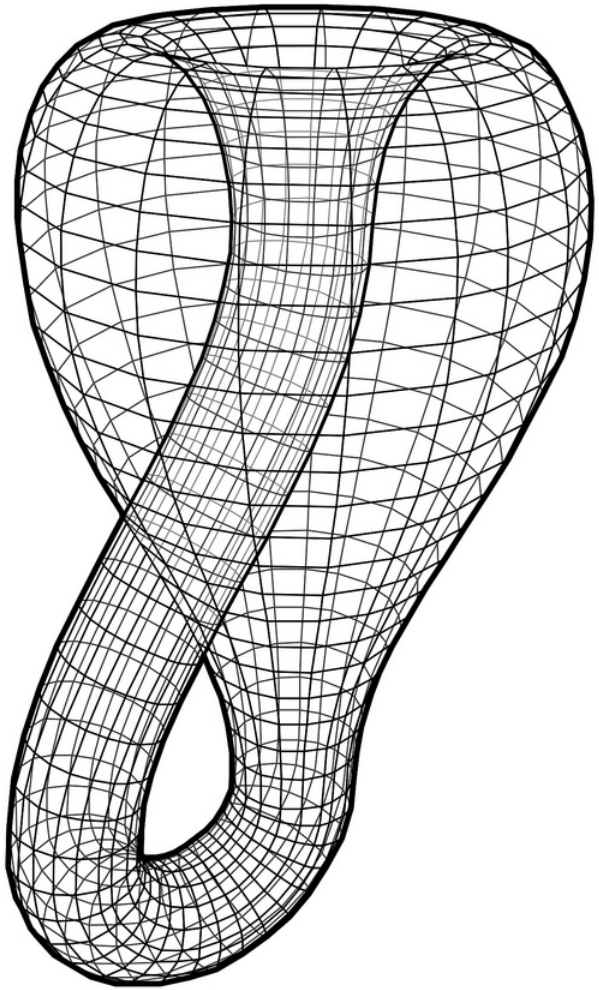

Evaluation des performances

$$Précision_i = \frac{vrai\ positifs_i}{vrai\ positifs_i + faux\ positif_i}$$

$$Précision = \frac{\sum_{i=1}^{n} précision_i}{n}$$

$$Rappel_i = \frac{vrai\ positifs_i}{vrai\ positifs_i + faux\ negatifs_i}$$

$$Rappel = \frac{\sum_{i=1}^{n} rappel_i}{n}$$

Evaluation des performances

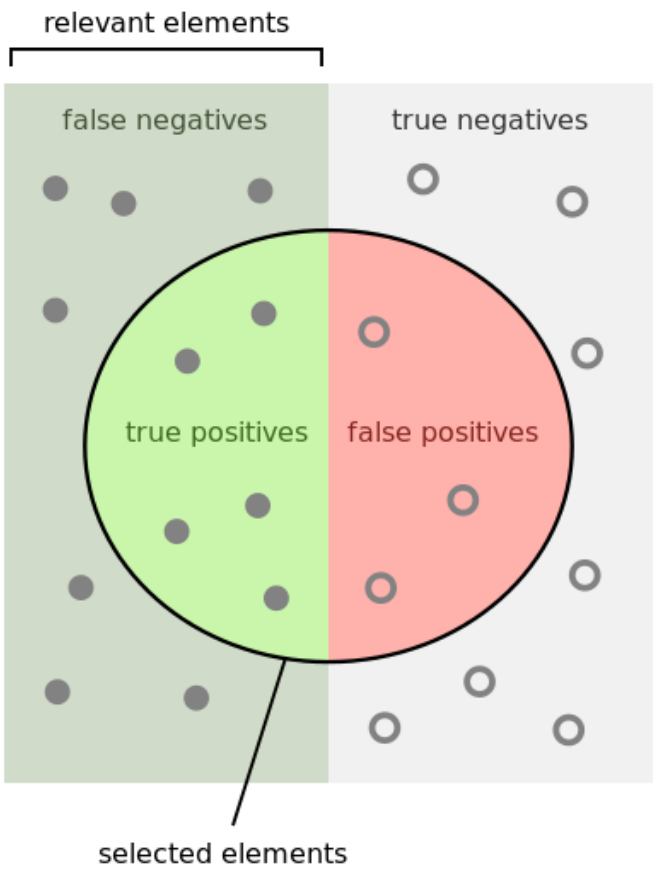

How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

Évaluation — outils — matrice de confusion