Machine Learning, méthodes et solutions

Évaluation et Apprentissage de modèles

Évaluation — outils — précision, rappel

En classification :

Précision

$$\frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux positifs}}$$

Rappel

$$\frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux négatifs}}$$

F-mesure moyenne harmonique entre précision et rappel (aussi appelée F1 score)

Évaluation — outils — précision, rappel

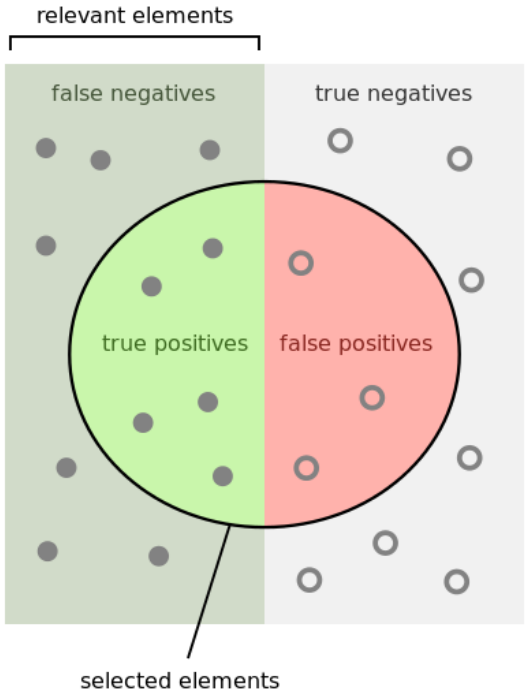

How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{selected elements}}$$

How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{relevant elements}}$$

Outils — courbe ROC

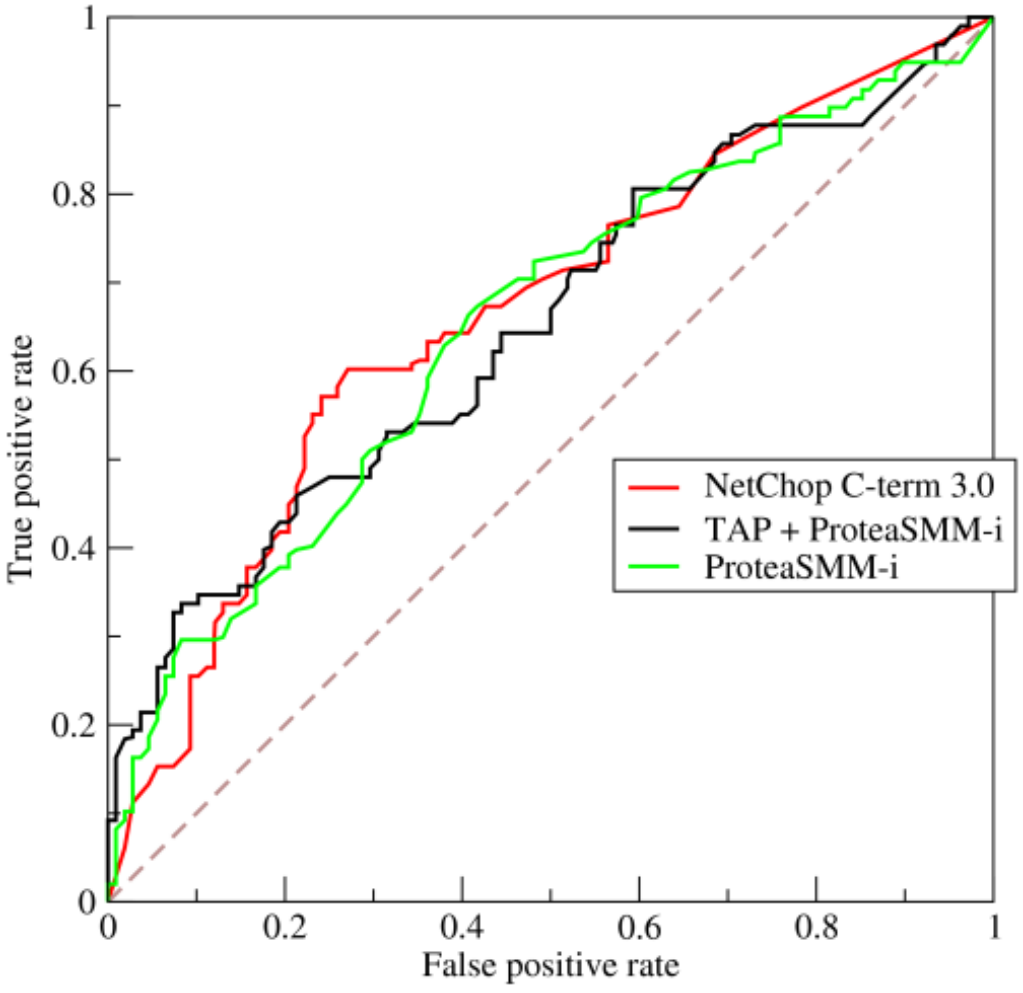

Outils — courbe ROC

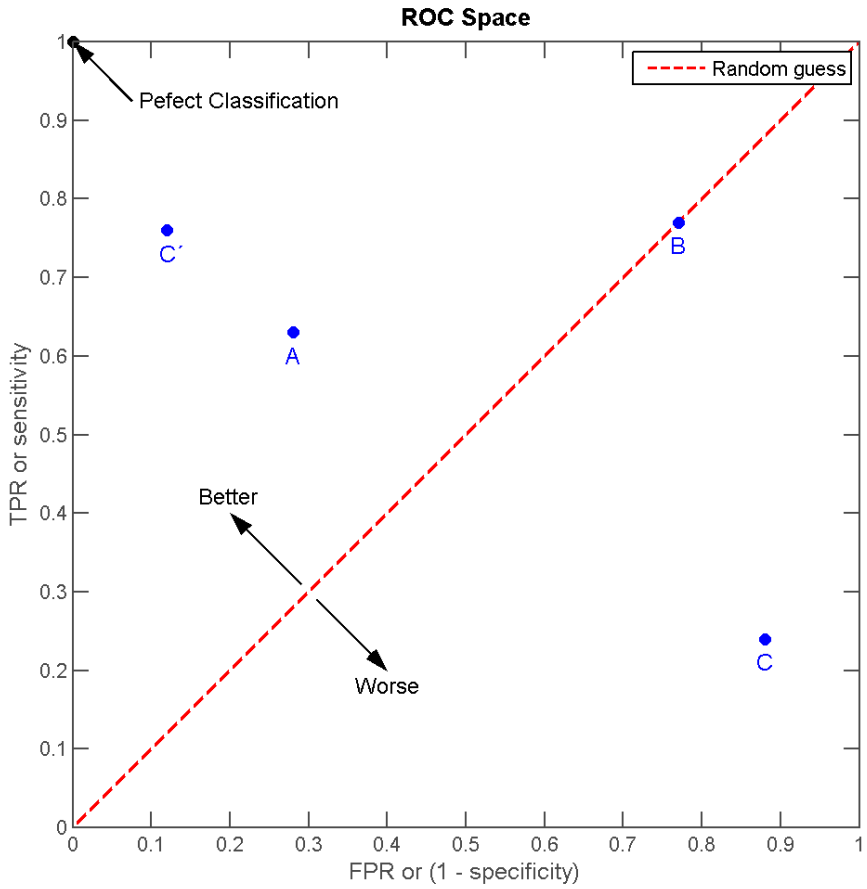

Évaluation — outils — matrice de confusion

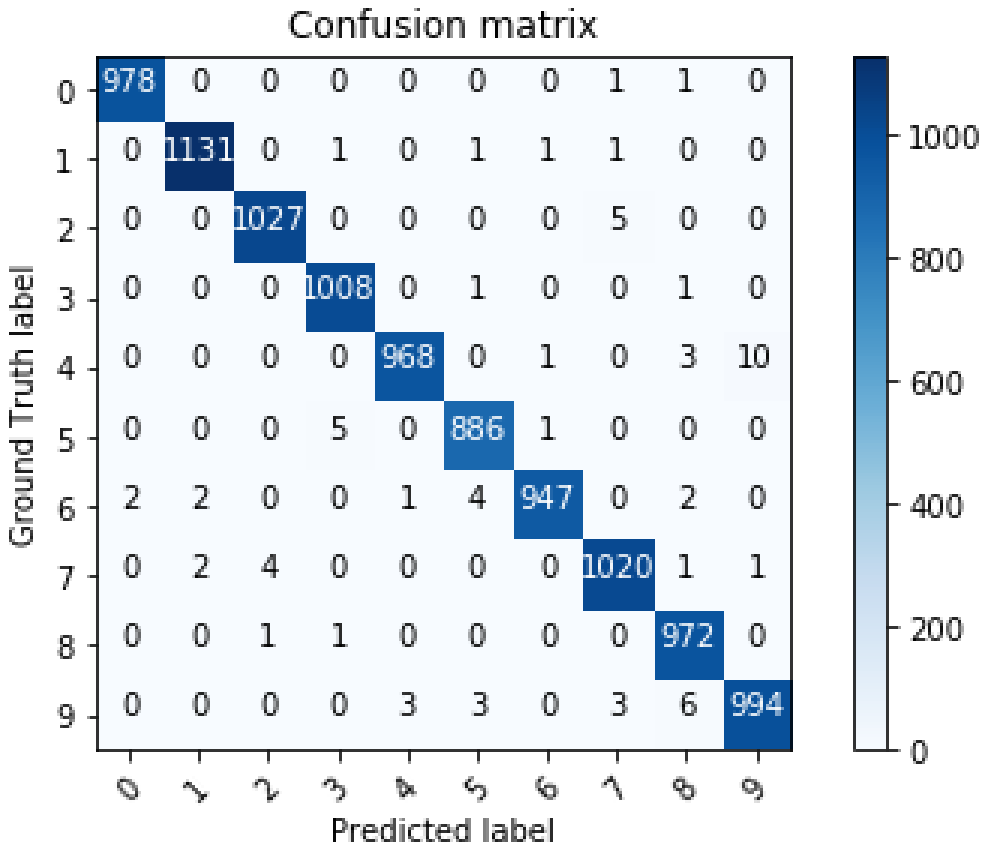

Apprentissage de modèles

Entrainement supervisé d'un modèle — overfit

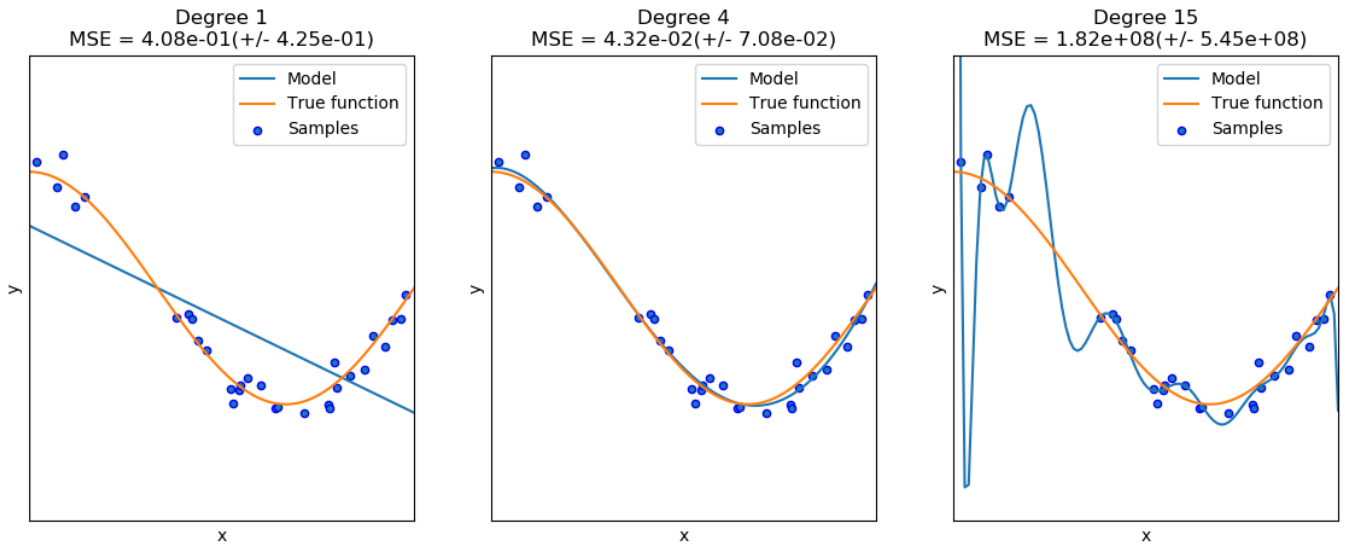

Problème : trop minimiser la perte n'est pas bon !

Apprentissage de modèles

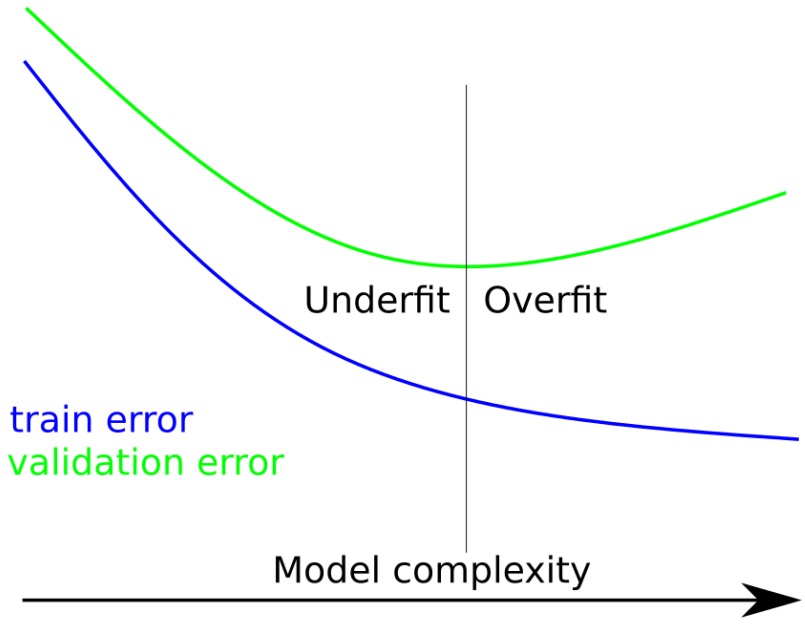

$\rightarrow$ Minimiser la perte sur un ensemble de validation

Apprentissage de modèles

Séparation des données :

- ensemble d'entrainement
- ensemble de validation pour mesurer la généralisation
- ensemble de test (pour éviter le biais statistique)

$\rightarrow$ Split 60/20/20 habituel.

Apprentissage de modèles

Idéalement : Cross Validation Pour « perdre » moins de données et mieux tester la généralisation, cross-validation :

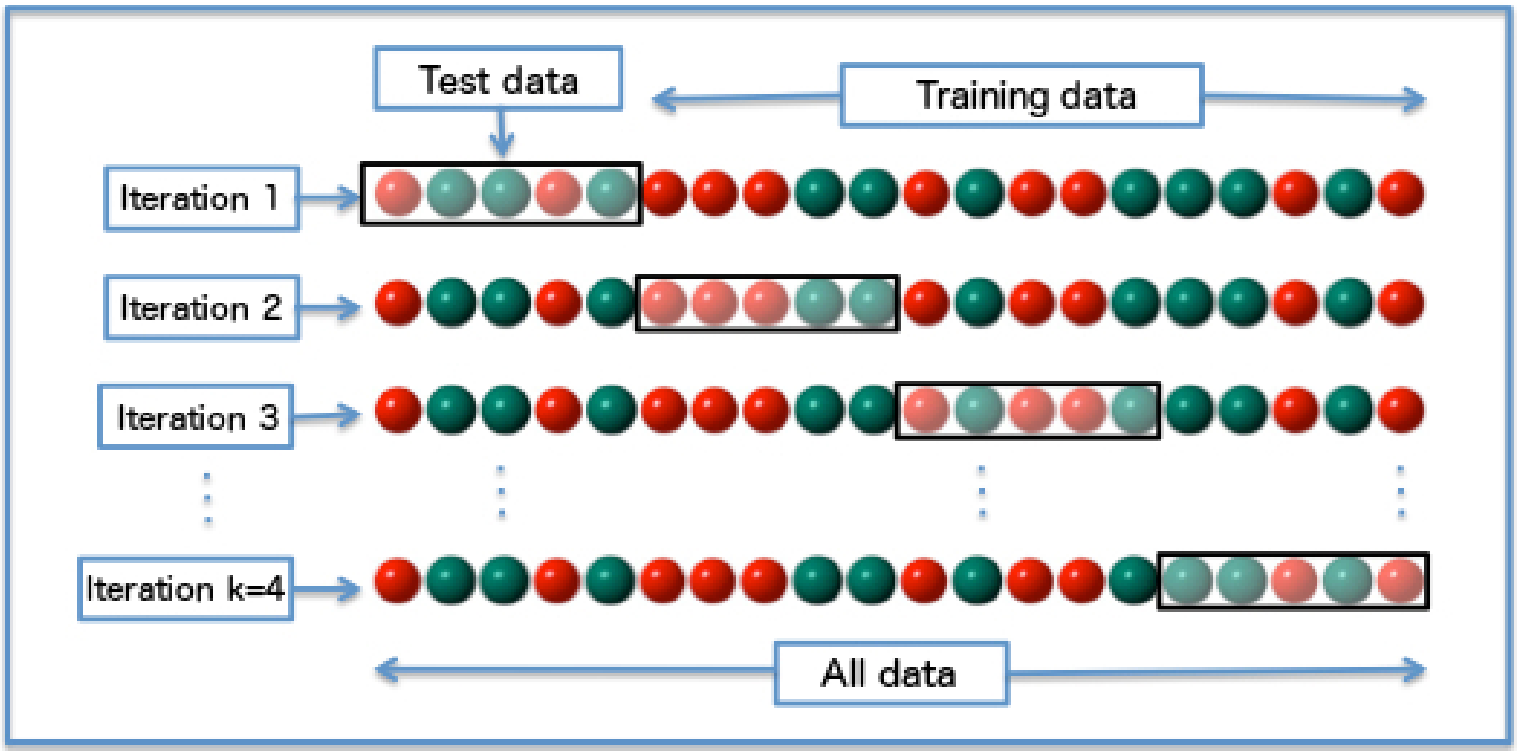

Ici, 4-fold cross-validation.

Apprentissage de modèles

1 - initialisation aléatoire du modèle

2 - Tant que(critère arret $==$ 0)

- Selection aléatoire d'un **batch** de données
- **Forward** : Passe avant du **batch** dans le modèle
- Calcul de l'erreur par rapport aux sorties attendues
- **Backward** : Rétropropagation du gradient de l'erreur en fonction des paramètres dans le modèle (mise à jour du modèle)
- Calcul critère arret

3 - Calcul de l'erreur sur un échantillon de données **qui n'ont JAMAIS été vues par le modèle pendant l'apprentissage !**

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features
- on définit quand même une perte (loss)

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features
- on définit quand même une perte (loss)

  Densité intra- et inter-clusters en clustering

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features
- on définit quand même une perte (loss)

  Densité intra- et inter-clusters en clustering

  Ou utiliser des données supervisées...

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features
- on définit quand même une perte (loss)

  Densité intra- et inter-clusters en clustering

  Ou utiliser des données supervisées... Pourcentage d'info perdue pour la réduction de dimentionnalité

Reproductibilité

- extrêmement importante pour compléter les analyses après les retours business
- ensemble de bonnes pratiques

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing
- de préférence utiliser des notebooks

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing
- de préférence utiliser des notebooks
- faire attention au random (utiliser des seeds)

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing
- de préférence utiliser des notebooks
- faire attention au random (utiliser des seeds)
- définir les datasets utilisés, dates comprises

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing
- de préférence utiliser des notebooks
- faire attention au random (utiliser des seeds)
- définir les datasets utilisés, dates comprises
- garder une trace de l'environnement

Méta-paramètres et Régularisation

Les méta-paramètres forment l'ensemble des prétraitements,la forme et les contraintes appliquées au modèle **AVANT** son apprentissage.

- Forme : Nombre de couches ?, de quelle taille ? ...
- L'algorithme d'optimisation (SGD, adaboost, adam,...)
- Méthodes de régularisation (norme des paramètres dans la loss, bruitage, dropout, ...)

Régularisation

$\approx$

empêcher le surapprentissage