Machine Learning, méthodes et solutions

(avec Python)

GIRAUD François-Marie

https ://www.orsys.fr/

Machine Learning, méthodes et solutions

Introduction à la Modélisation de Données

Votre formateur

Nom	Giraud François-Marie
Courriel	giraud.francois@gmail.com
Activité	Consultant/Formateur indépendant
Spécialité	Intelligence Artificielle
Parcours	Master Intelligence Artificielle et Décision (Paris 6)

Votre formation — description

Cette formation présente les **fondamentaux** de la **Modélisation Statistique** à travers des travaux pratiques.

Votre formation — connaissances préalables

- Connaissances de base en statistiques
- Connaissances de base en python
- Avoir un **compte Google** afin de pouvoir faire les TPs dans Google colaboratory

Votre formation — objectifs à atteindre

- Comprendre les différents modèles d'apprentissage
- Modéliser un problème pratique par le machine learning
- Identifier les méthodes adaptées à un problème donnée
- Évaluer la performance de la solution
- Se familiariser avec les librairies scientifiques python (NumPy, seaborn, sikit-learn, ...)

Votre formation — programme

- 4 jours de 9h à 12h30 et de 14h à 17h30
- Le dernier jour on finit à 15h30
- À 15h on commence à remplir les documents administratifs.

Votre formation — programme

- Introduction à la modélisation
- Evaluation de modèles prédictifs
- Les algorithmes supervisés/non-supervisés
- Réduction de dimension
- Données séquentielles (temporelles)

Votre formation — ressources

- Je vous ferai parvenir les ressources utilisées à chaque début de cours.
- Elles sont aussi accessibles via https ://myorsys.orsys.fr/

Tour de table — présentez-vous

- Votre nom
- Votre métier
- Vos compétences dans les domaines liés à cette formation
- Vos objectifs et vos attentes vis-à-vis de cette formation

Machine Learning, méthodes et solutions

Introduction à Python

Introduction à Python

Python est créé en 1989 par Guido Van Russum.

En 2001 création de la Python Software Foundation.

Python est sous licence GPL depuis 2001.

Python 3 depuis 2009

Introduction à Python

- Langage **interprété**
  - Compilé à la volée
- Orienté **Objet**
  - Paradigme objet (mais pas que)
- **Portable**
  - Compatible avec toutes les plateformes actuelles
- Un couteau suisse **puissant** et **populaire**
  - À chaque besoin, une librairie
  - Les librairies importés sont compilées en C/C++

Introduction à Python

Atouts

- Stable
- multi-plateforme
- Facile à apprendre
- Grande communauté (le plus utilisé depuis 2019)
- un besoin, un module

Inconvénients

- Non-compilé
  - Plus lent qu'un langage bas-niveau
  - Optimiser une opération $\Rightarrow$ pas facile à apprendre

Introduction à Python

Différents interpréteurs :

- Python/CPython $\Rightarrow$ C
- Jython $\Rightarrow$ Java
- IronPython $\Rightarrow$ .Net

Domaines d'applications :

- Web (Django ,Flask, ...)
- Sciences (Data mining, Machine learning, Physique, ...)
- OS (Linux, Raspberry, Script administration système, ...)
- Éducation (Initiation à la programmation)
- CAO 3D (FreeCAD, pythonCAD, ...)
- Multimédia (Kodi, ...)

Introduction à Python

Syntaxe à typage dynamique sans délimiteurs de blocs :

```
1  a="une chaine de caracteres"
2  b=a
3  a=8
4
5  if a > 5:
6      print('a=',a,'; b=',b)
7  else:
8      print("c'est étrange")
```

```
1  a= 8 ; b= une chaine de caracteres
```

Machine Learning, méthodes et solutions

Notebook Jupyter

Notebook Jupyter

Jupyter est un environnement de développement via une interface web.
Plus de 40 langages de programmation sont supportés, dont le python.

Notebook Jupyter

Une démonstration vaut mieux qu'un long discours :

Jupyter Notebook Demo

Machine Learning, méthodes et solutions

Installation de Anaconda

Installation de Anaconda

Anaconda est une distribution Python faite pour la “Data Science”

Installation de Anaconda

Ce qui sera installé après ce tutoriel :

- Python
- Jupyter Notebook
- Des librairies de “Data Science” :
  - SciPy, Numpy
  - Pandas, seaborn
  - scikit-learn, statsmodels
  - Matplotlib

Installation de Anaconda

Installation d'Anaconda

Installation de Anaconda

Une fois installé, lancez le navigateur Anaconda puis cliquez sur “Jupyter”.
Chargez le fichier “Anaconda.ipynb” que vous trouverez dans le dossier “ressources/”.
Editez et Exécutez les cellules pour prendre en main cet environnement de développement.

Machine Learning, méthodes et solutions

Machine Learning

Machine Learning

Machine Learning

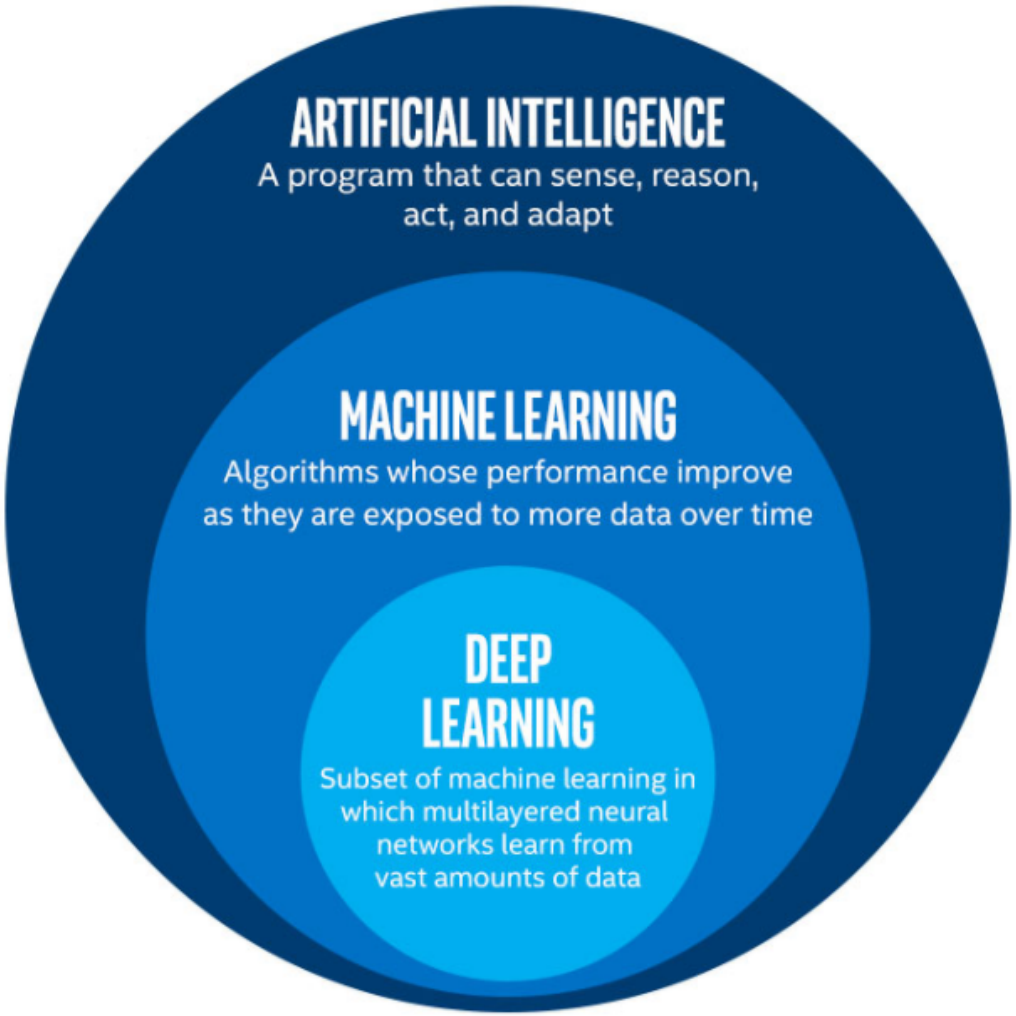

Machine Learning

Nouvelle manière d'aborder la **conception logicielle**.

$$\boxed{\textit{Programmation Implicite} \neq \textit{Programmation Explicite}}$$

Machine Learning

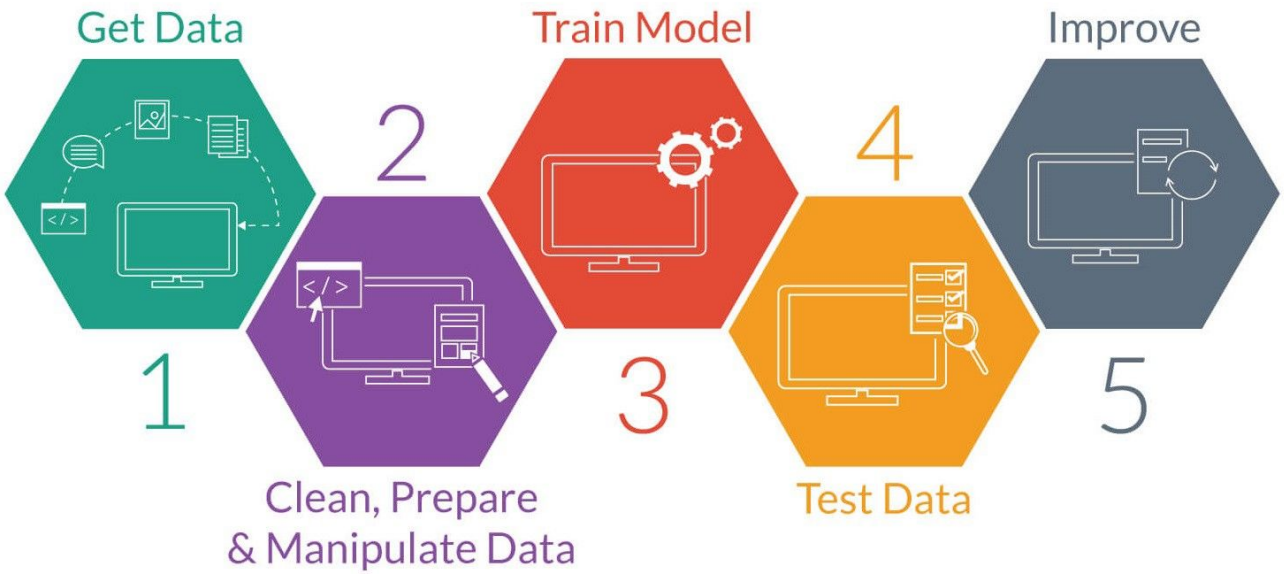

Machine Learning

Définition du besoin :

Apprentissage **supervisé** ou **non-supervisé** ?

Apprentissage non-supervisé

Faire émerger des profils, des groupes

Ex : groupes de clients pour adapter sa stratégie marketing

Apprentissage supervisé

Prédire une valeur numérique (**régression**) ou l'appartenance à une classe (**Classification**)

Ex (Régression) : Prédire le poid d'un individu en fonction de l'âge, la taille et le sexe.
Ex (Classification) : Prédire si une image est un chat ou un chien.

Régression Linéaire :

$Y = a * X + b$

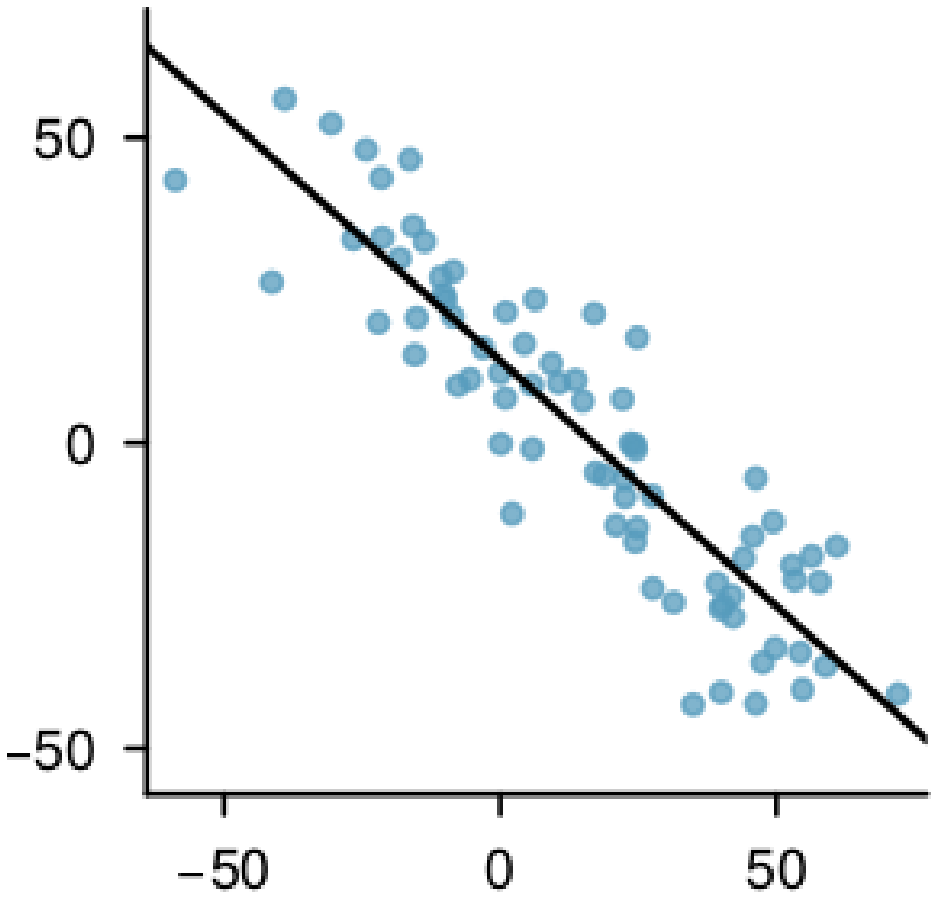

Régression Linéaire pour des données en plusieurs dimensions :

$Y = a * X_1 + b * X_2 + c$

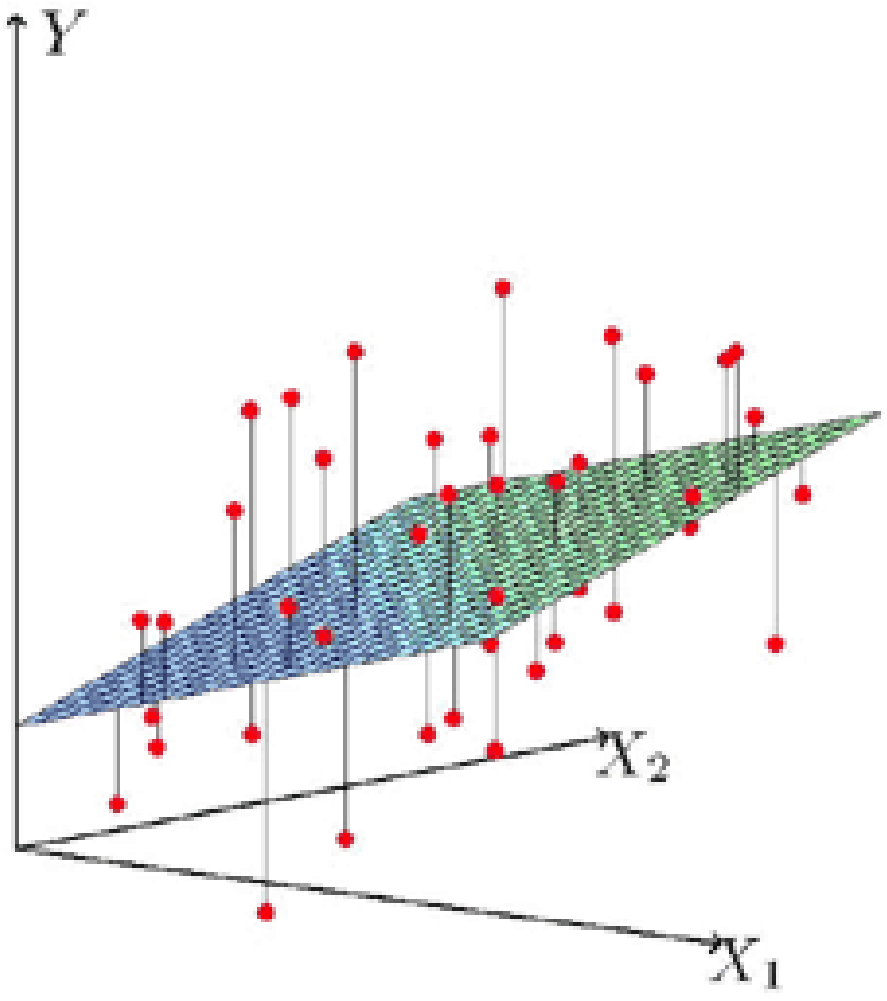

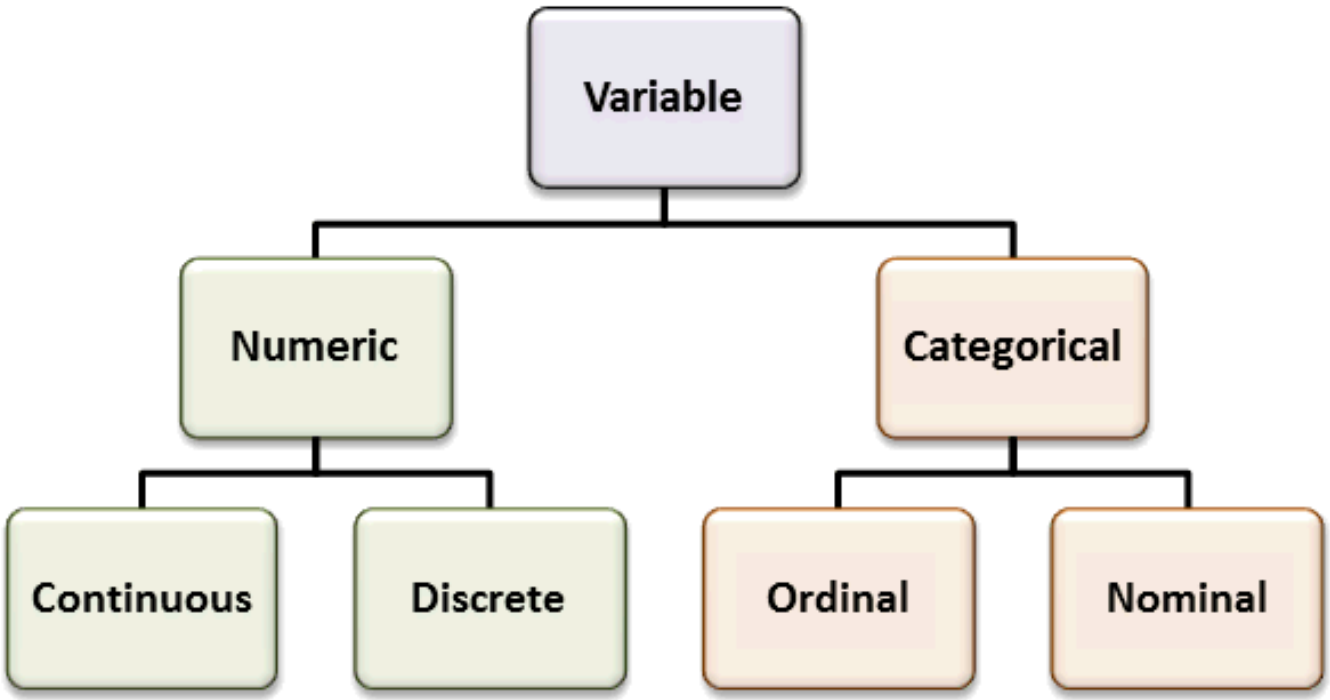
Variable
Numeric
Categorical
Continuous
Discrete
Ordinal
Nominal

Régression Logistique (Classification)

Régression Logistique (Classification)

001.ak47

002.american-flag

003.backpack

004.baseball-bat

005.baseball-glove

006.basketball-hoop

007.bat

008.bathtub

009.bear

010.beer-mug

011.billiards

012.binoculars

Apprentissage par Renforcement

Apprendre une **stratégie** efficace dans un **univers** où les **actions** fournissent des **récompenses** (possiblement négatives)

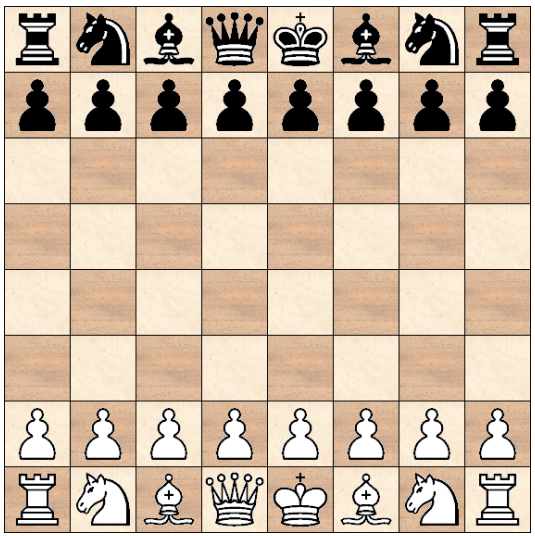

Machine Learning

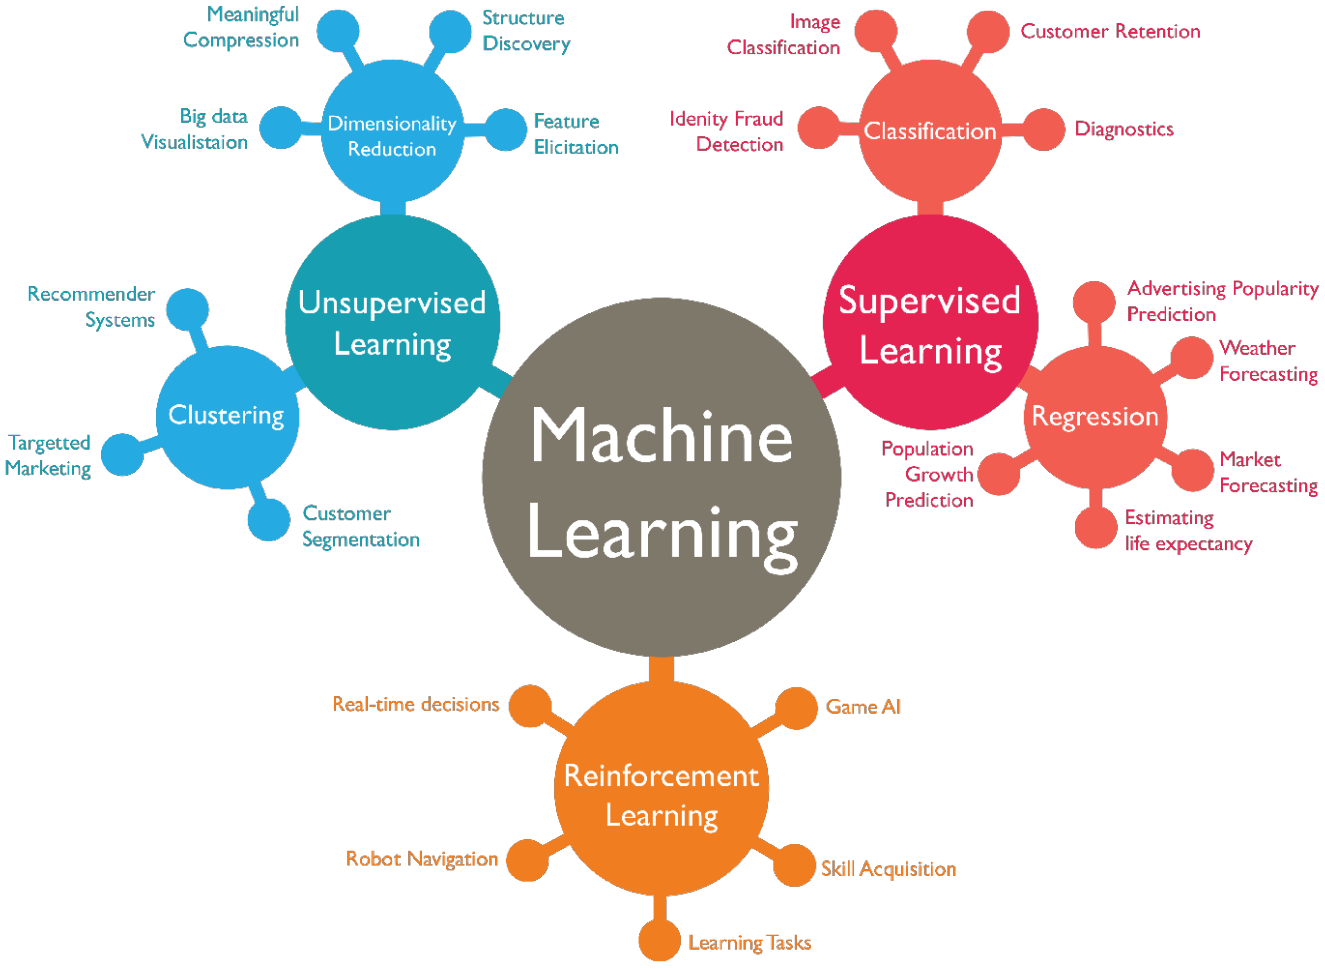

Machine Learning, méthodes et solutions

Data Mining

Data Mining

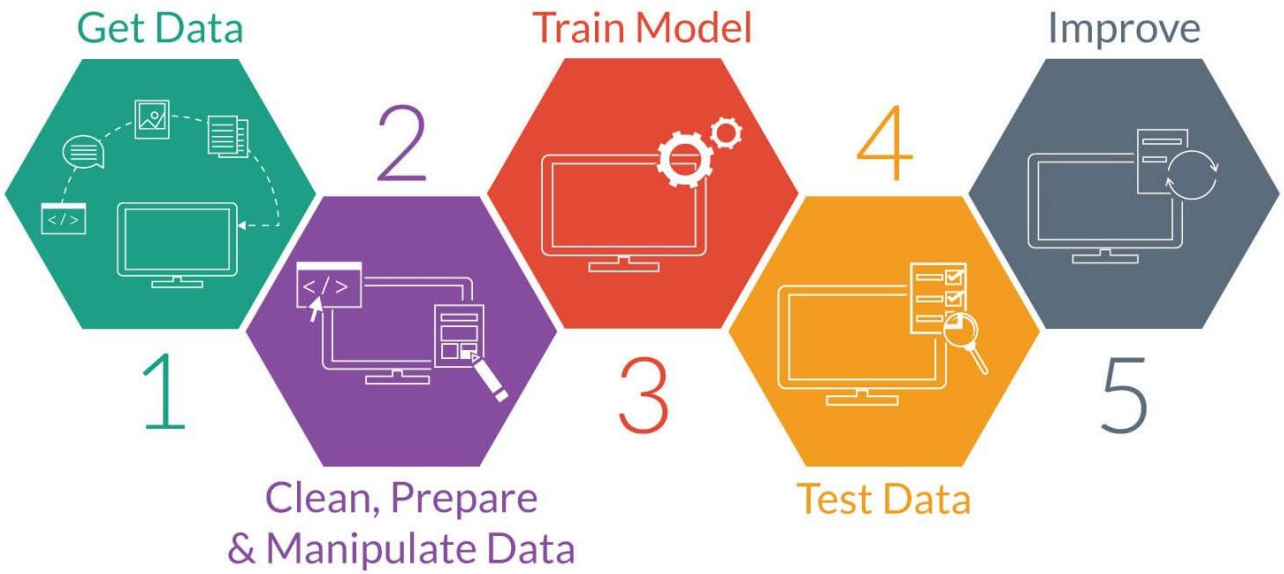
Get Data
1
2
Clean, Prepare
& Manipulate Data
Train Model
3
4
Test Data
Improve
5

Data Mining

Attention aux différents biais de vos données !

- variables confondantes (Ex : “obésité” dans la corrélation entre “conso. viande” et “cancer colon”)

Data Mining

Attention aux différents biais de vos données !

- variables confondantes (Ex : “obésité” dans la corrélation entre “conso. viande” et “cancer colon”)
- biais statistiques

Data Mining

Attention aux différents biais de vos données !

- variables confondantes (Ex : “obésité” dans la corrélation entre “conso. viande” et “cancer colon”)
- biais statistiques
  - sélection, autosélection

Data Mining

Attention aux différents biais de vos données !

- variables confondantes (Ex : “obésité” dans la corrélation entre “conso. viande” et “cancer colon”)
- biais statistiques
  - sélection, autosélection
  - mesure

Data Mining

Attention aux différents biais de vos données !

- variables confondantes (Ex : “obésité” dans la corrélation entre “conso. viande” et “cancer colon”)
- biais statistiques
  - sélection, autosélection
  - mesure
  - attrition

Data Mining

Attention aux différents biais de vos données !

- variables confondantes (Ex : “obésité” dans la corrélation entre “conso. viande” et “cancer colon”)
- biais statistiques
  - sélection, autosélection
  - mesure
  - attrition
  - ...

Data Mining

Attention aux différents biais de vos données !

- variables confondantes (Ex : “obésité” dans la corrélation entre “conso. viande” et “cancer colon”)
- biais statistiques
  - sélection, autosélection
  - mesure
  - attrition
  - ...
- trouver de fausses variables explicatives

Data Mining

Attention aux différents biais de vos données !

- variables confondantes (Ex : “obésité” dans la corrélation entre “conso. viande” et “cancer colon”)
- biais statistiques
  - sélection, autosélection
  - mesure
  - attrition
  - ...
- trouver de fausses variables explicatives

Data Mining

Attention aux différents biais de vos données !

- variables confondantes (Ex : “obésité” dans la corrélation entre “conso. viande” et “cancer colon”)
- biais statistiques
  - sélection, autosélection
  - mesure
  - attrition
  - ...
- trouver de fausses variables explicatives

$\rightarrow$ Le garder en tête pendant toute l'étude.

Data Mining

Meilleures données $>$ Meilleurs modèles
(trash-in, trash-out)

$\rightarrow$ À garder en tête pendant toute l'étude, en particulier durant l'entraînement de modèles

Préparation des données

- valeurs manquantes
- préprocessing (texte, image)
- standardisation
- transformation

Préparation des données — valeurs manquantes

Gênant pour certains modèles. Plusieurs options :

- supprimer les enregistrements

Préparation des données — valeurs manquantes

Gênant pour certains modèles. Plusieurs options :

- supprimer les enregistrements
- remplacer par une valeur (imputation) :

Préparation des données — valeurs manquantes

Gênant pour certains modèles. Plusieurs options :

- supprimer les enregistrements
- remplacer par une valeur (imputation) :
  - constante

Préparation des données — valeurs manquantes

Gênant pour certains modèles. Plusieurs options :

- supprimer les enregistrements
- remplacer par une valeur (imputation) :
  - constante
  - moyenne de la colonne

Préparation des données — valeurs manquantes

Gênant pour certains modèles. Plusieurs options :

- supprimer les enregistrements
- remplacer par une valeur (imputation) :
  - constante
  - moyenne de la colonne
  - prédiction d'un autre modèle

Préparation des données — préprocessing

- tokenizer, POS-tagger le texte (`https://spacy.io/`)
- utiliser un réseau de neurones préentraîné sur les images (`https://keras.io/applications/`)
- appliquer une transformée de fourier sur le son
- ...

Préparation des données — standardisation

Beaucoup de modèles travaillent mieux avec des données normales et sont plus efficaces autour de $[-5, 5]$:

- centrer sur la moyenne puis diviser par l'écart-type
- transformation de Box-Cox en cas d'asymétrie
- transformations spécifiques en fonction de la distribution

Préparation des données — transformation

Quand un modèle n'accepte pas de données catégorielles :

- label encoding si ordinal
- one-hot encoding sinon

Préparation des données — label encoding

Si les données sont ordinales :

Ordinal :

Température
Froid
Froid
Tiède
Chaud
Tiède

Label encoding :

Température
1
1
2
3
2

Préparation des données — one-hot encoding

Remplacer une feature par n features avec n le nombre de catégories.

Catégoriel :

Couleur
Rouge
Rouge
Jaune
Vert
Jaune

One-hot :

Rouge	Jaune	Vert
1	0	0
1	0	0
0	1	0
0	0	1
0	1	0

Exploration des données

But :

- se rendre compte des prétraitements à effectuer (Box-Cox, imputations, etc)

Exploration des données

But :

- se rendre compte des prétraitements à effectuer (Box-Cox, imputations, etc)
- comprendre la variable de sortie : distribution, équilibre des classes, features les plus corrélées, ...

Exploration des données

But :

- se rendre compte des prétraitements à effectuer (Box-Cox, imputations, etc)
- comprendre la variable de sortie : distribution, équilibre des classes, features les plus corrélées, ...
- détecter les corrélations

Exploration des données

But :

- se rendre compte des prétraitements à effectuer (Box-Cox, imputations, etc)
- comprendre la variable de sortie : distribution, équilibre des classes, features les plus corrélées, ...
- détecter les corrélations
- appréhender la complexité nécessaire du modèle

Exploration des données

But :

- se rendre compte des prétraitements à effectuer (Box-Cox, imputations, etc)
- comprendre la variable de sortie : distribution, équilibre des classes, features les plus corrélées, ...
- détecter les corrélations
- appréhender la complexité nécessaire du modèle

Attention : garder des données de côté (test set) et ne pas les regarder.
Sinon biais statistique énorme.

Outils

Plusieurs outils sont disponibles pour explorer des données. On utilise principalement des plots pour :

- se renseigner sur une distribution
- se renseigner sur la corrélation de deux distributions
- visualiser des corrélations linéaires

Les outils suivants sont sauf mention contraire présents dans `seaborn`.

Outils — count plot

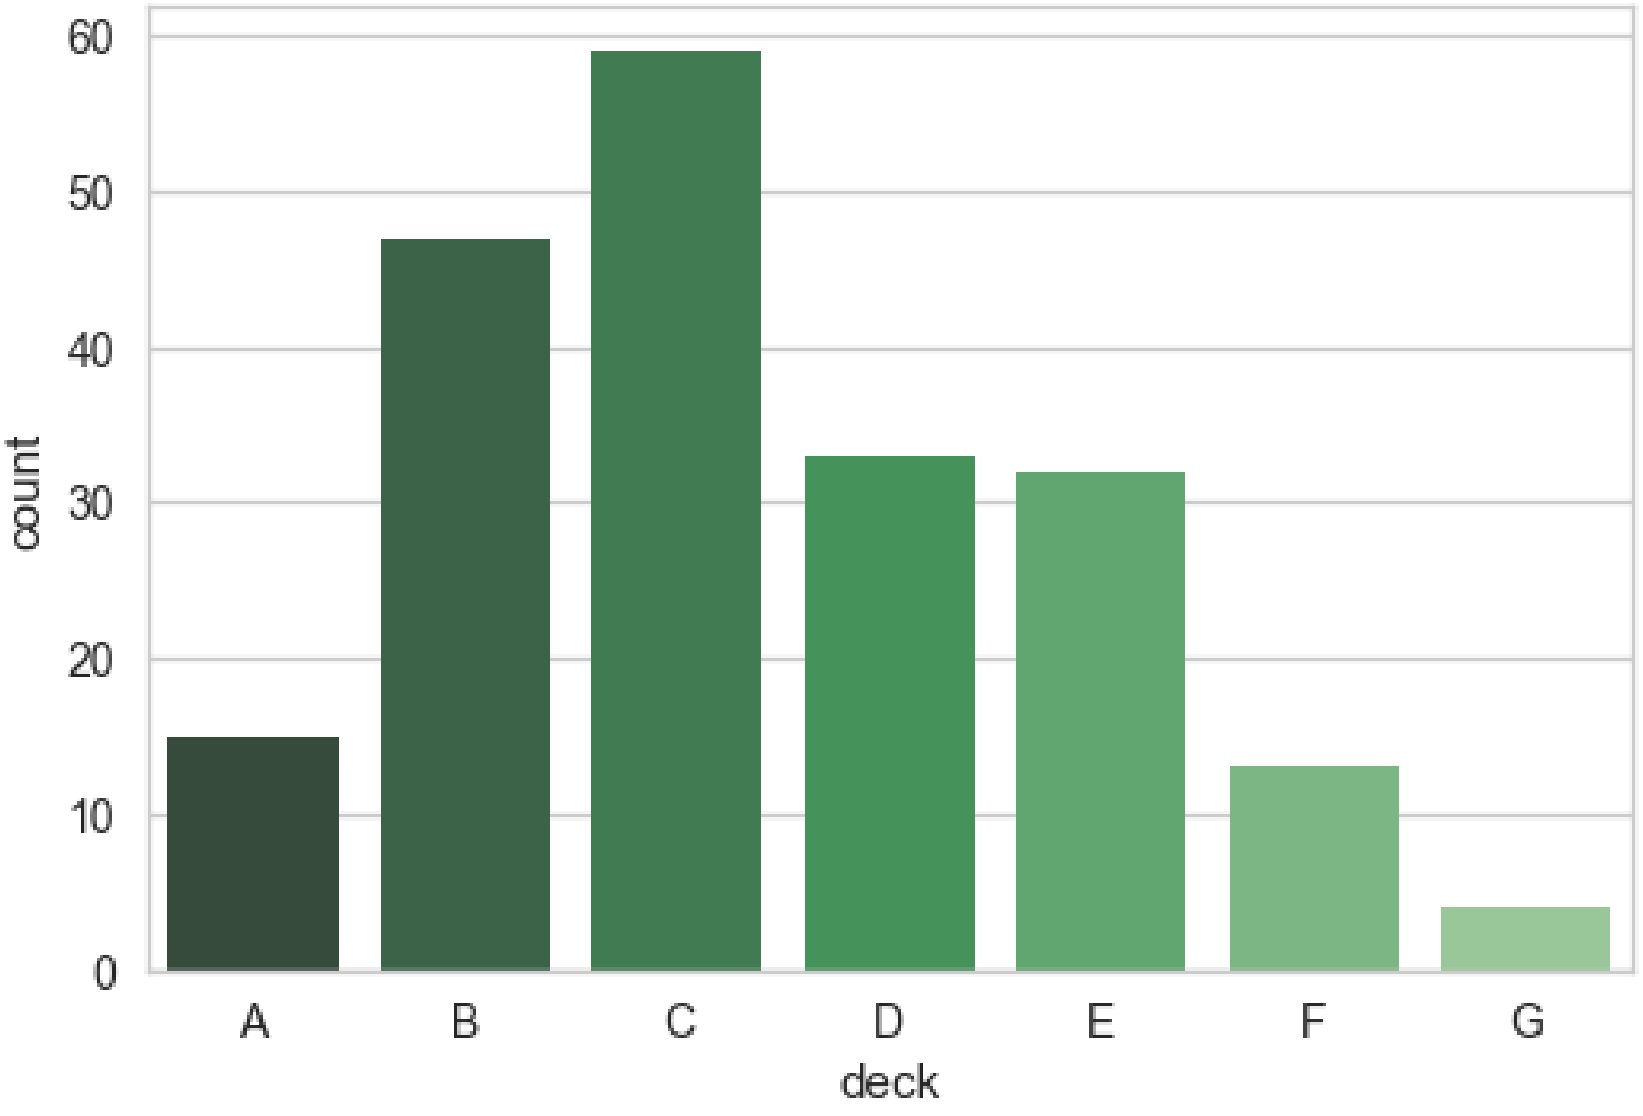

Outils — dist plot

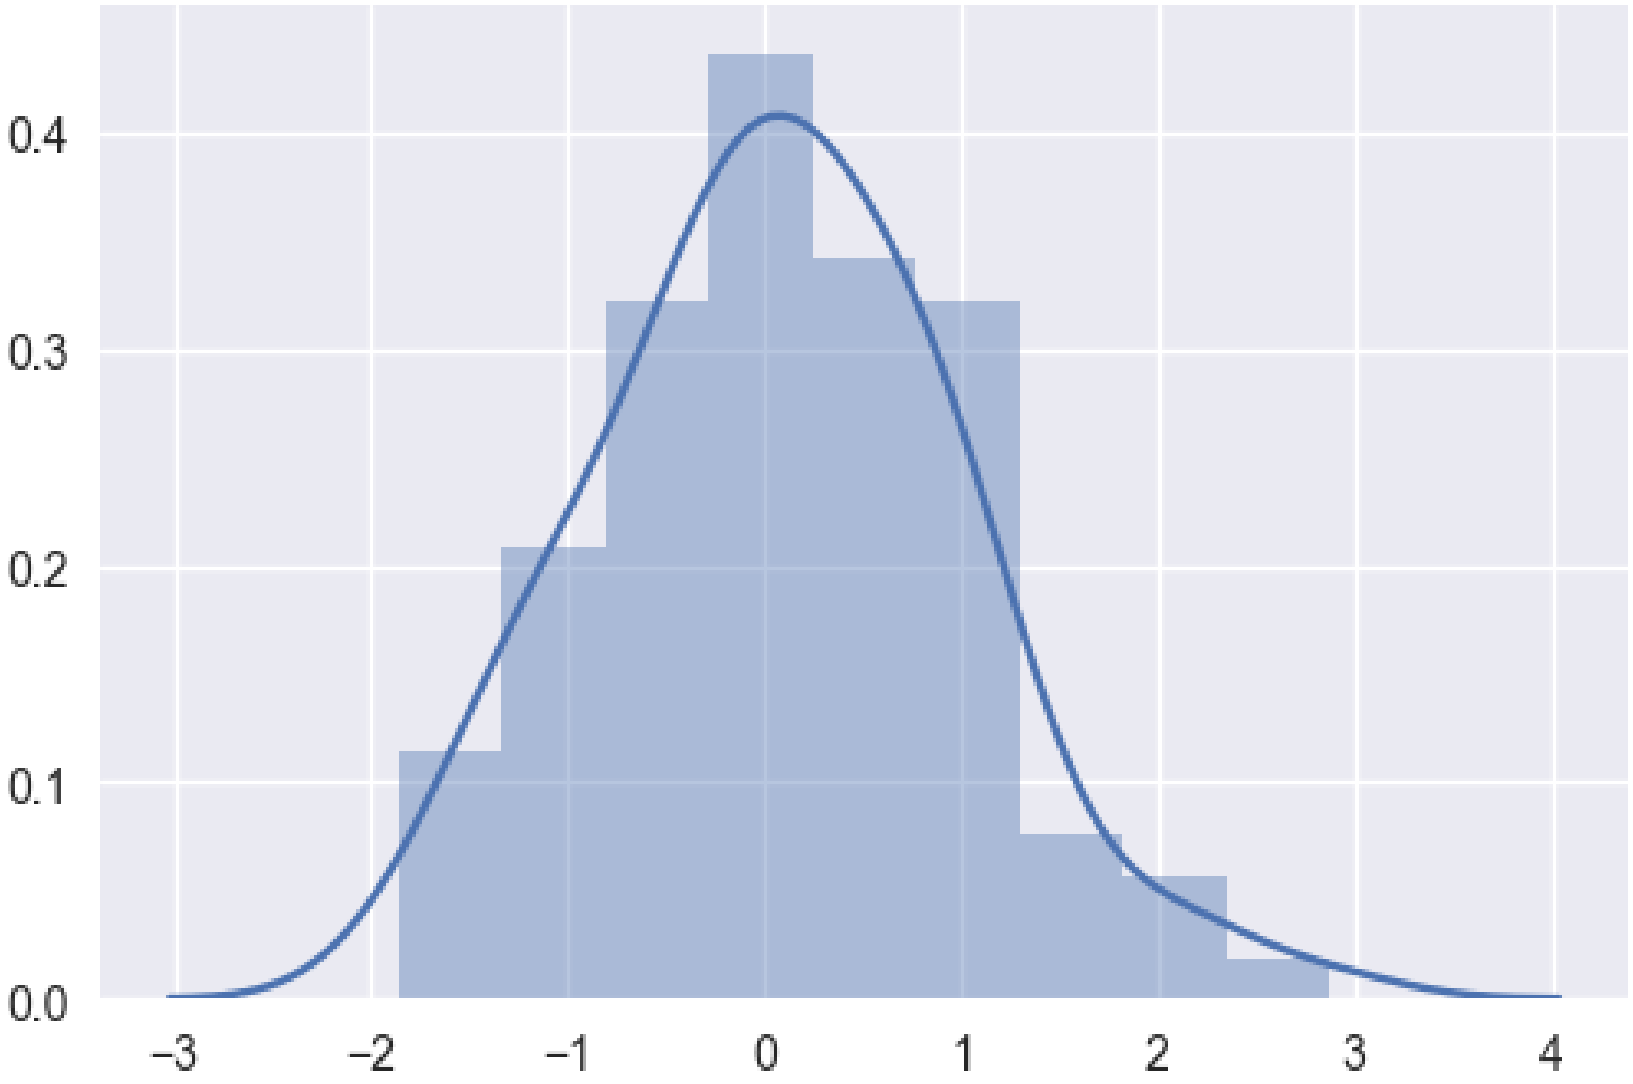

Outils — qq plot

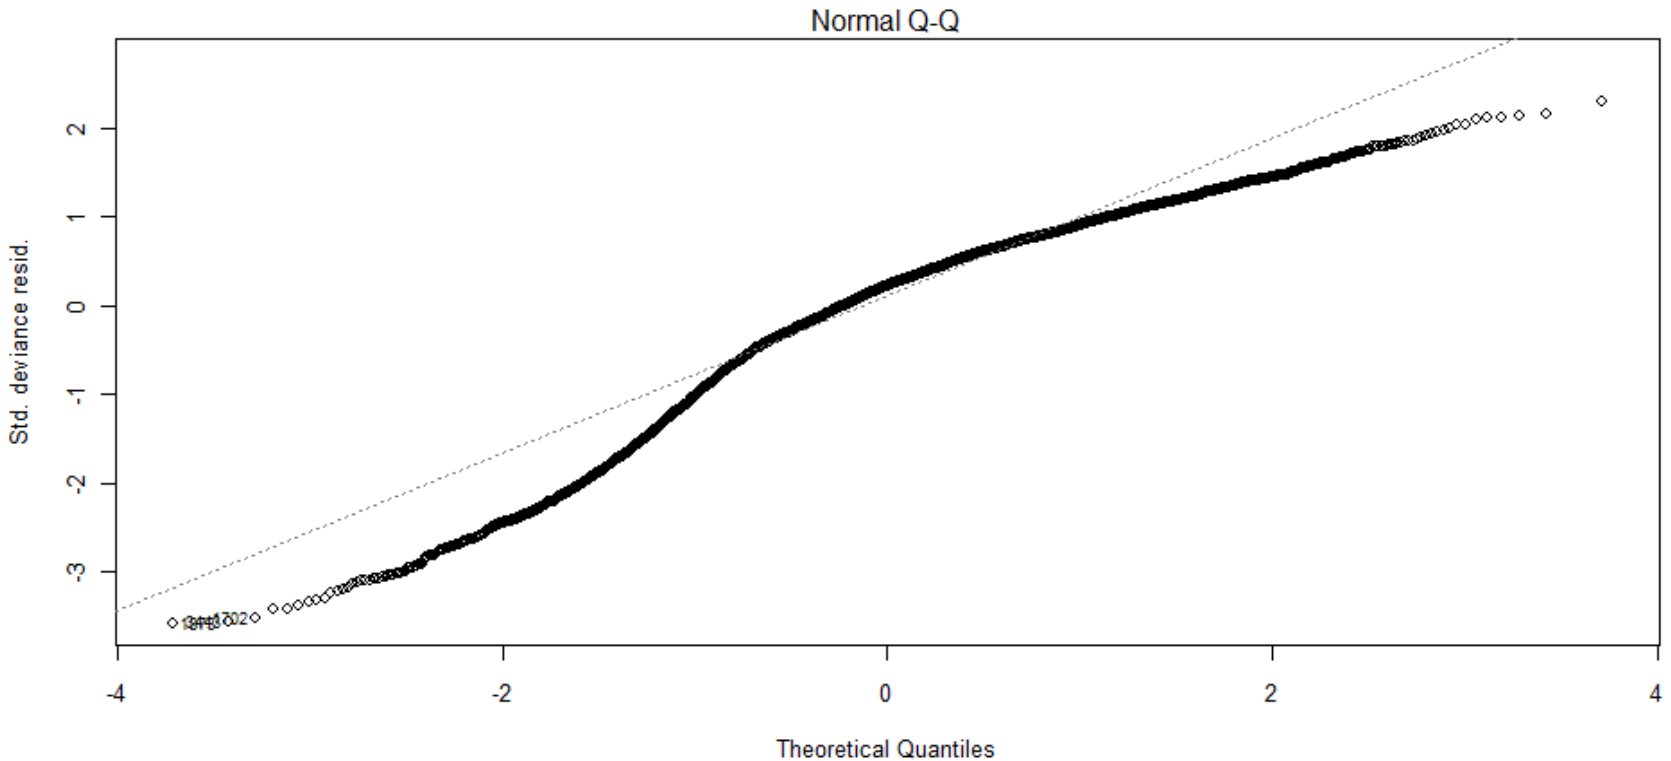

Attention, pas `seaborn` mais `statsmodel` ou `scipy.stats`.

Outils — bar plot

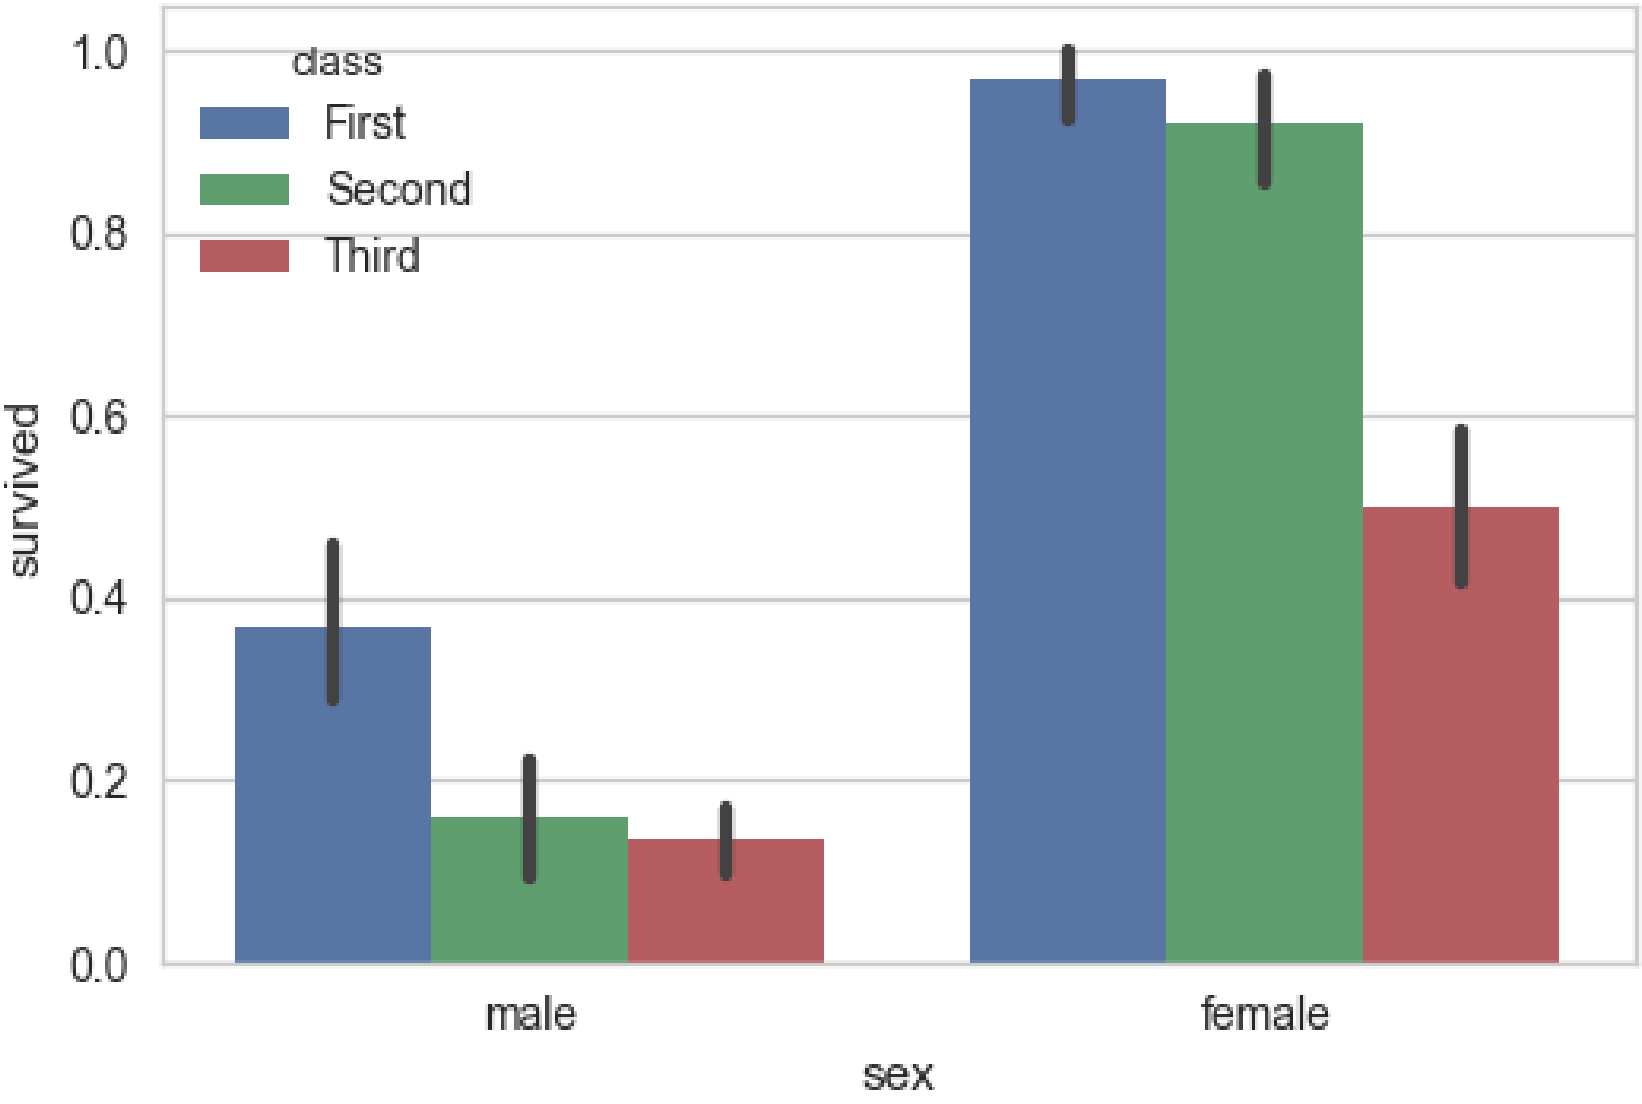

Outils — scatter plot

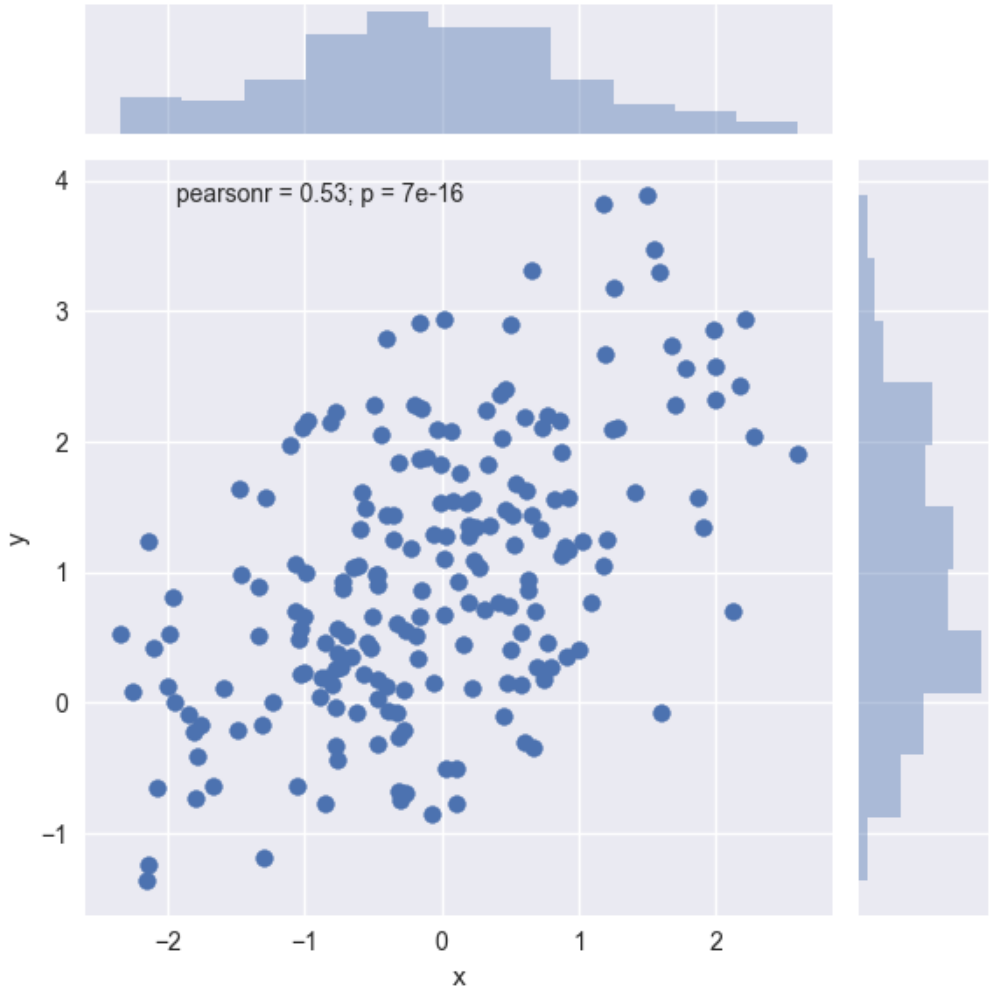

Outils — violin plot

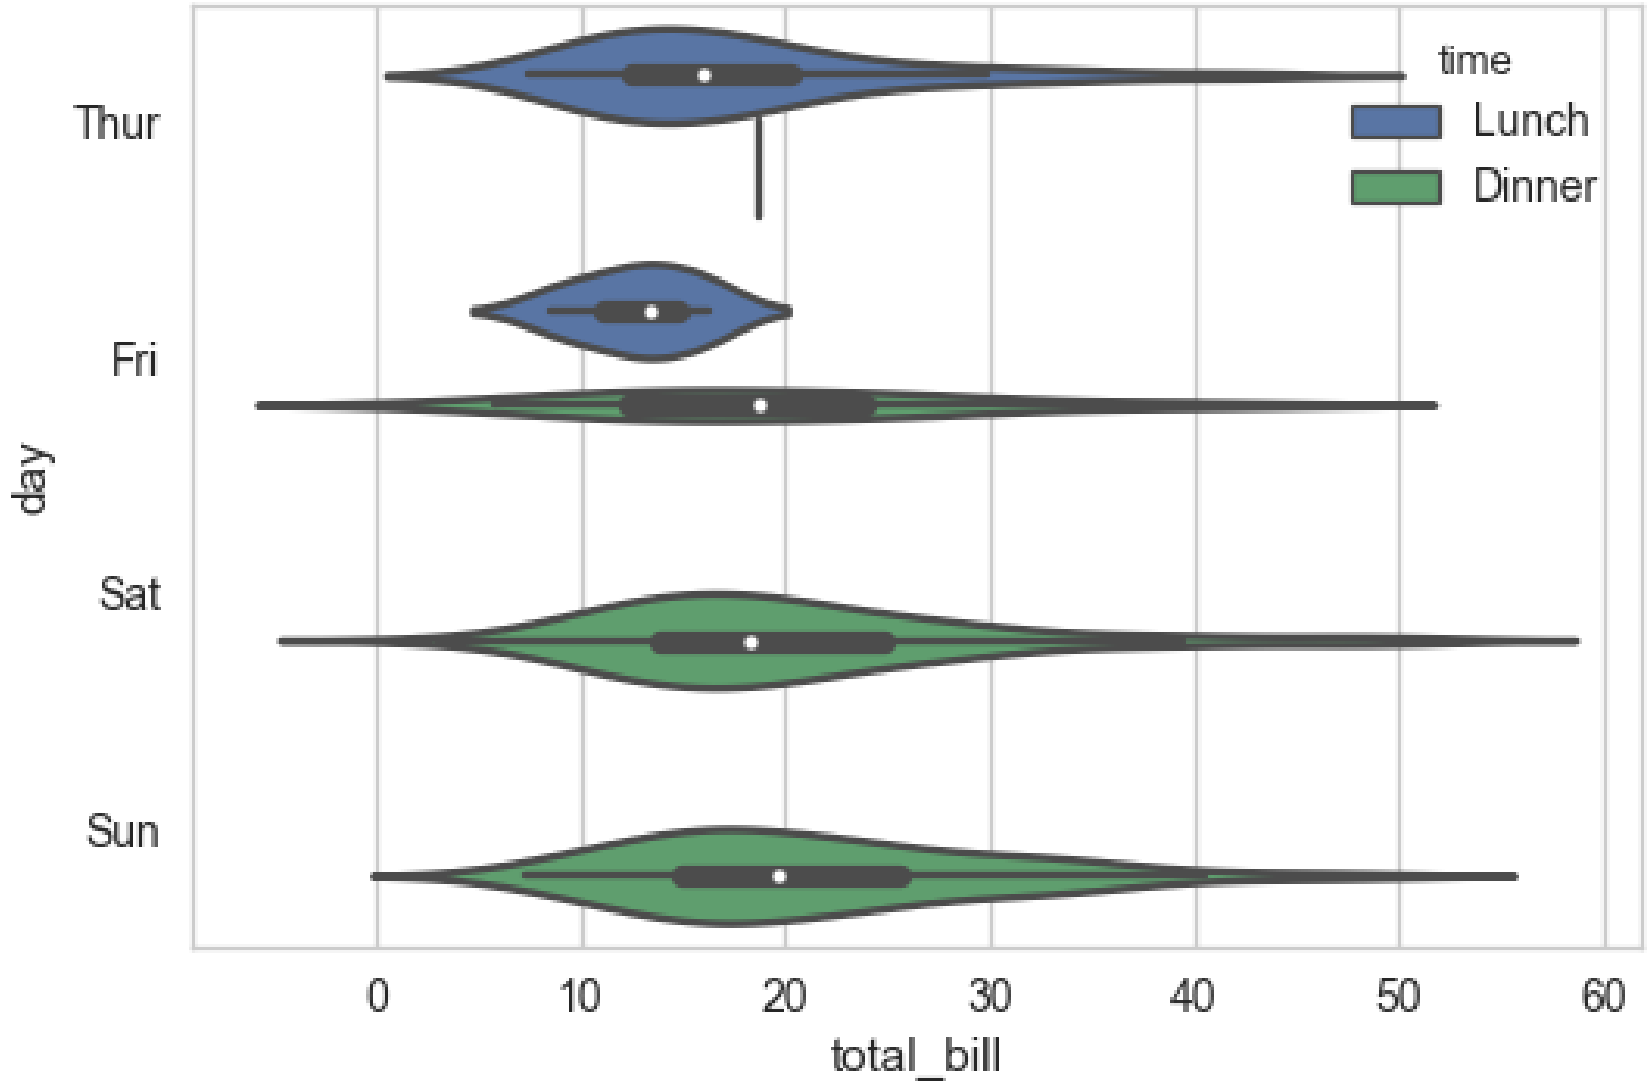

Outils — pair plot

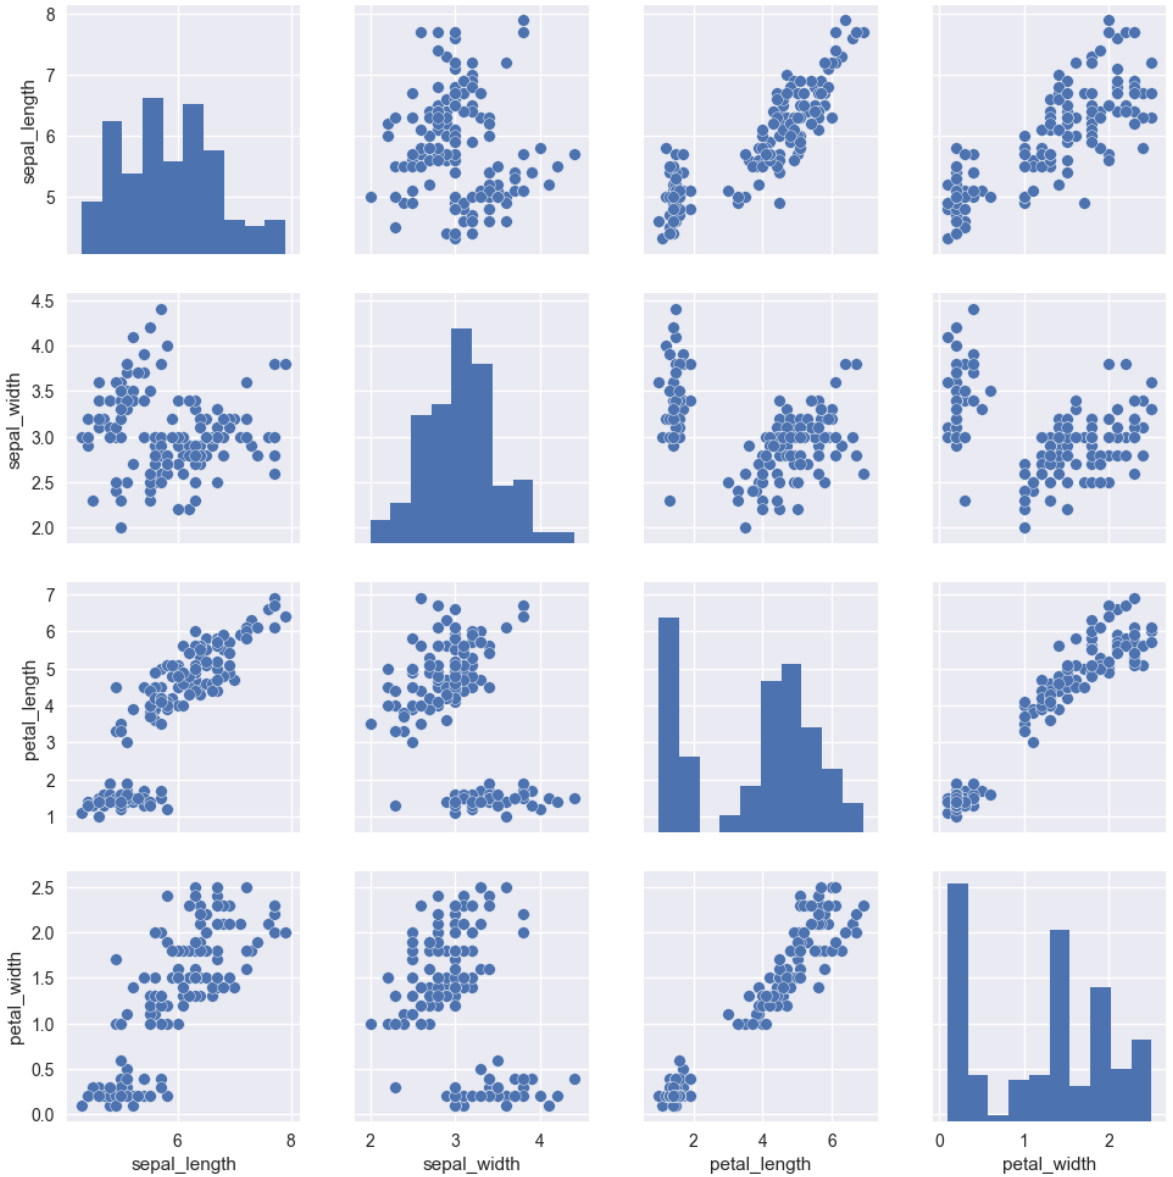

Outils — correlation matrix

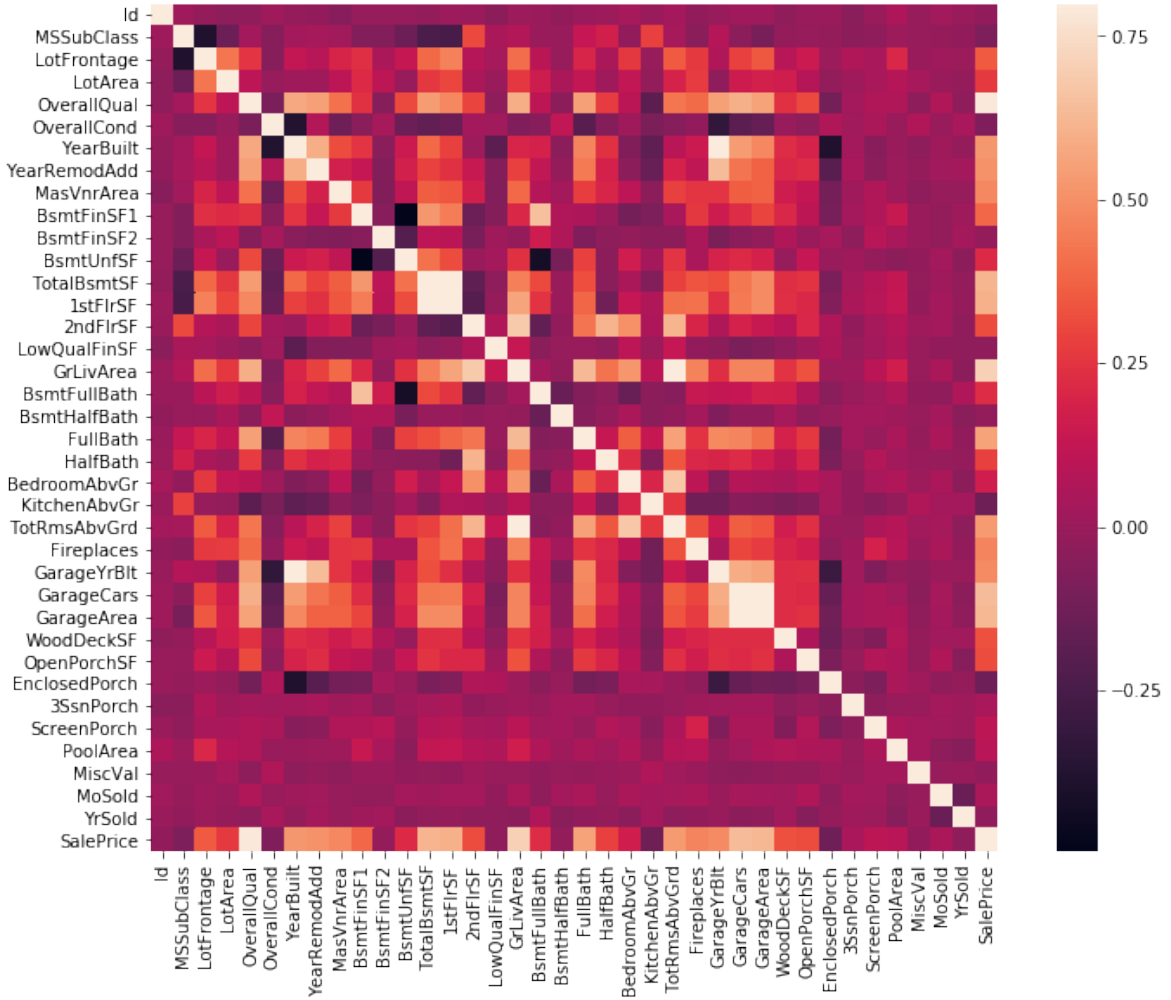

Mode opératoire

Bonnes pratiques pour explorer un dataset :

- analyser la(es) variable(s) de sortie (countplot/distplot)

Mode opératoire

Bonnes pratiques pour explorer un dataset :

- analyser la(es) variable(s) de sortie (countplot/distplot)
- trouver les corrélations linéaires les plus fortes

Mode opératoire

Bonnes pratiques pour explorer un dataset :

- analyser la(es) variable(s) de sortie (countplot/distplot)
- trouver les corrélations linéaires les plus fortes
- analyser les variables correspondantes

Mode opératoire

Bonnes pratiques pour explorer un dataset :

- analyser la(es) variable(s) de sortie (countplot/distplot)
- trouver les corrélations linéaires les plus fortes
- analyser les variables correspondantes
- regarder s'il y a des outliers évidents dans ces variables

Machine Learning, méthodes et solutions

Évaluation et Apprentissage de modèles

Évaluation — outils — précision, rappel

En classification :

Précision

$$\frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux positifs}}$$

Rappel

$$\frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux négatifs}}$$

F-mesure moyenne harmonique entre précision et rappel (aussi appelée F1 score)

Évaluation — outils — précision, rappel

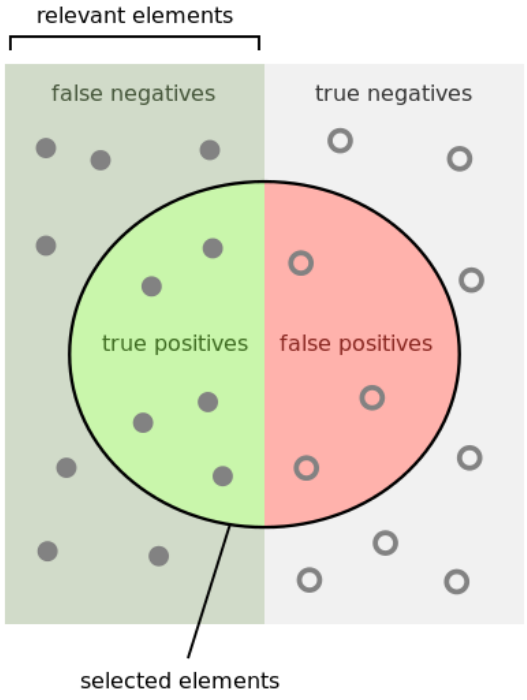

How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{selected elements}}$$

How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{relevant elements}}$$

Outils — courbe ROC

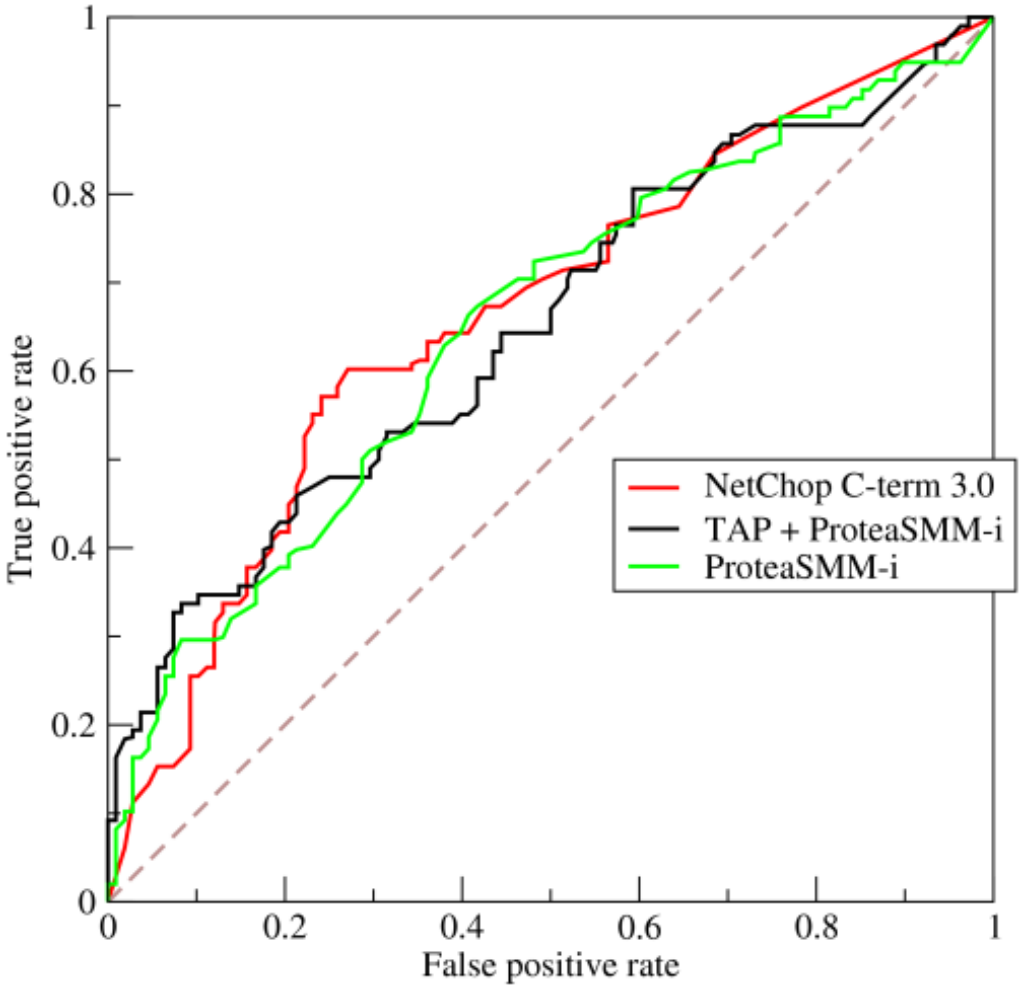

Outils — courbe ROC

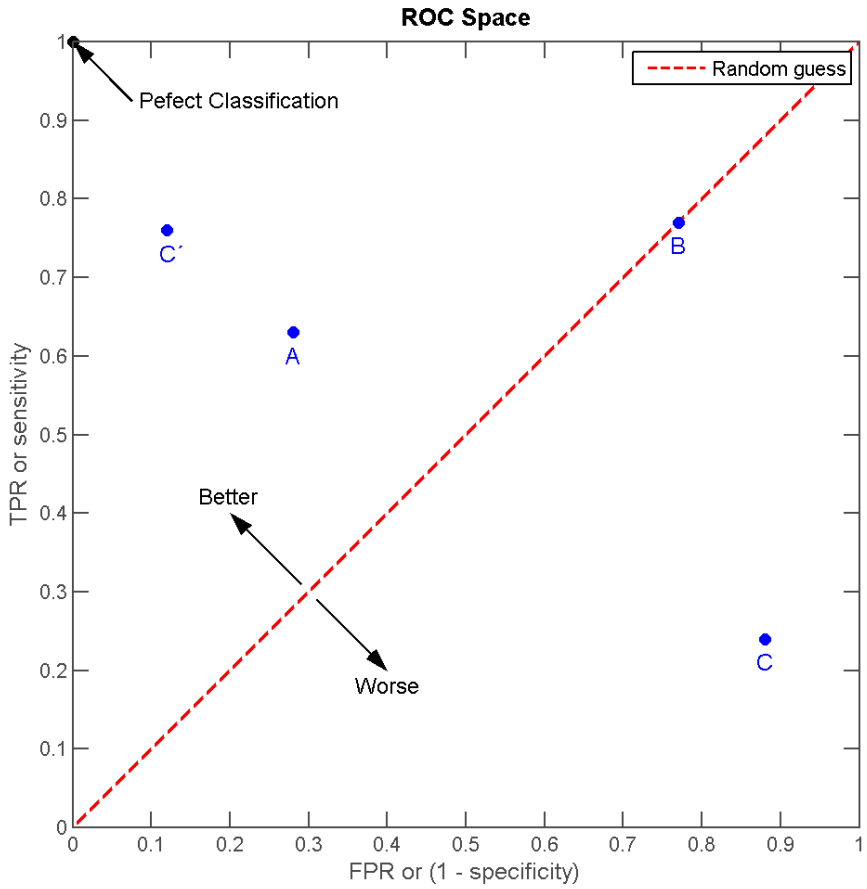

Évaluation — outils — matrice de confusion

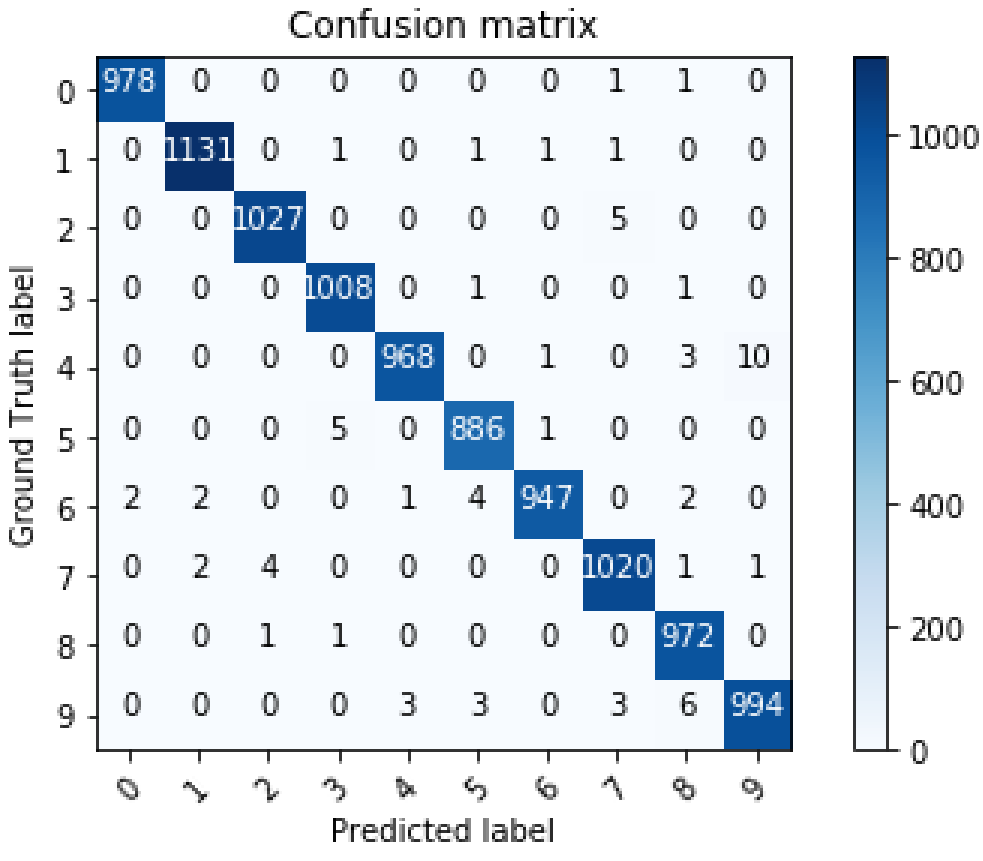

Apprentissage de modèles

Entrainement supervisé d'un modèle — overfit

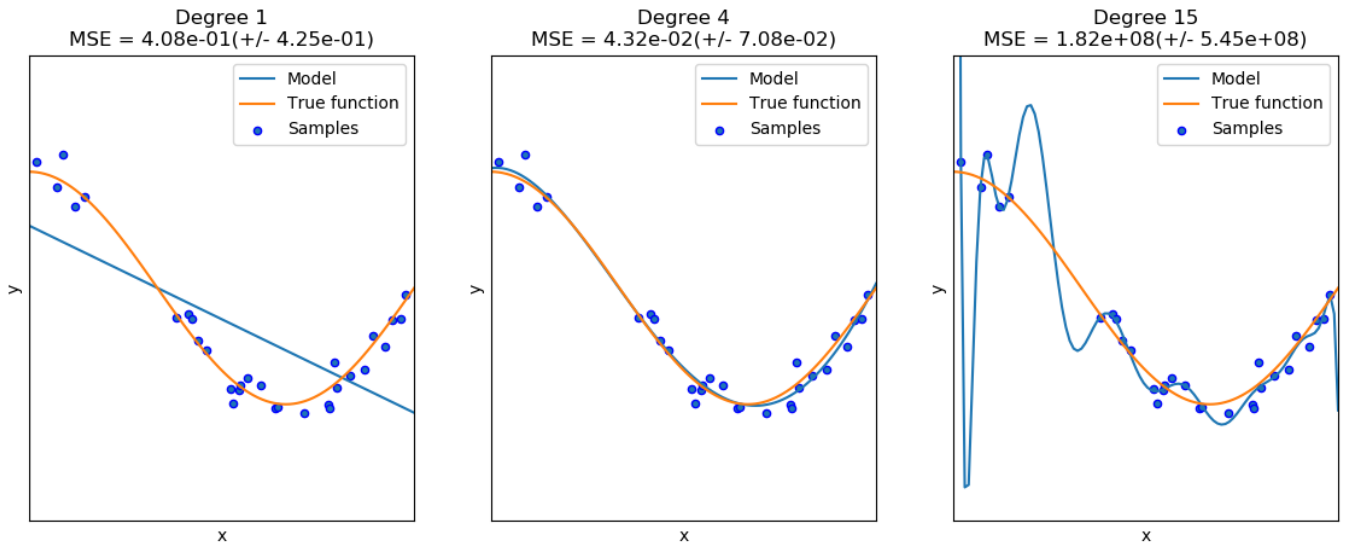

Problème : trop minimiser la perte n'est pas bon !

Apprentissage de modèles

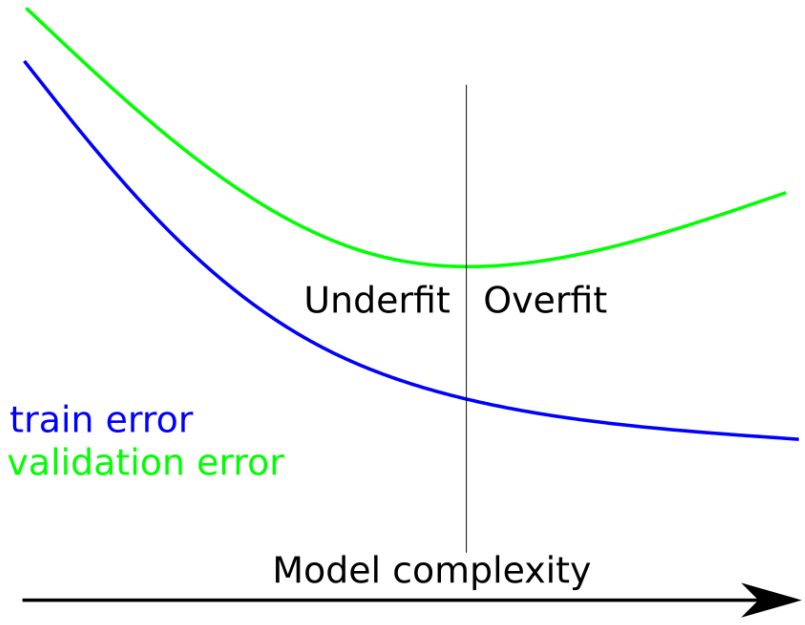

$\rightarrow$ Minimiser la perte sur un ensemble de validation

Apprentissage de modèles

Séparation des données :

- ensemble d'entrainement
- ensemble de validation pour mesurer la généralisation
- ensemble de test (pour éviter le biais statistique)

$\rightarrow$ Split 60/20/20 habituel.

Apprentissage de modèles

Idéalement : Cross Validation Pour « perdre » moins de données et mieux tester la généralisation, cross-validation :

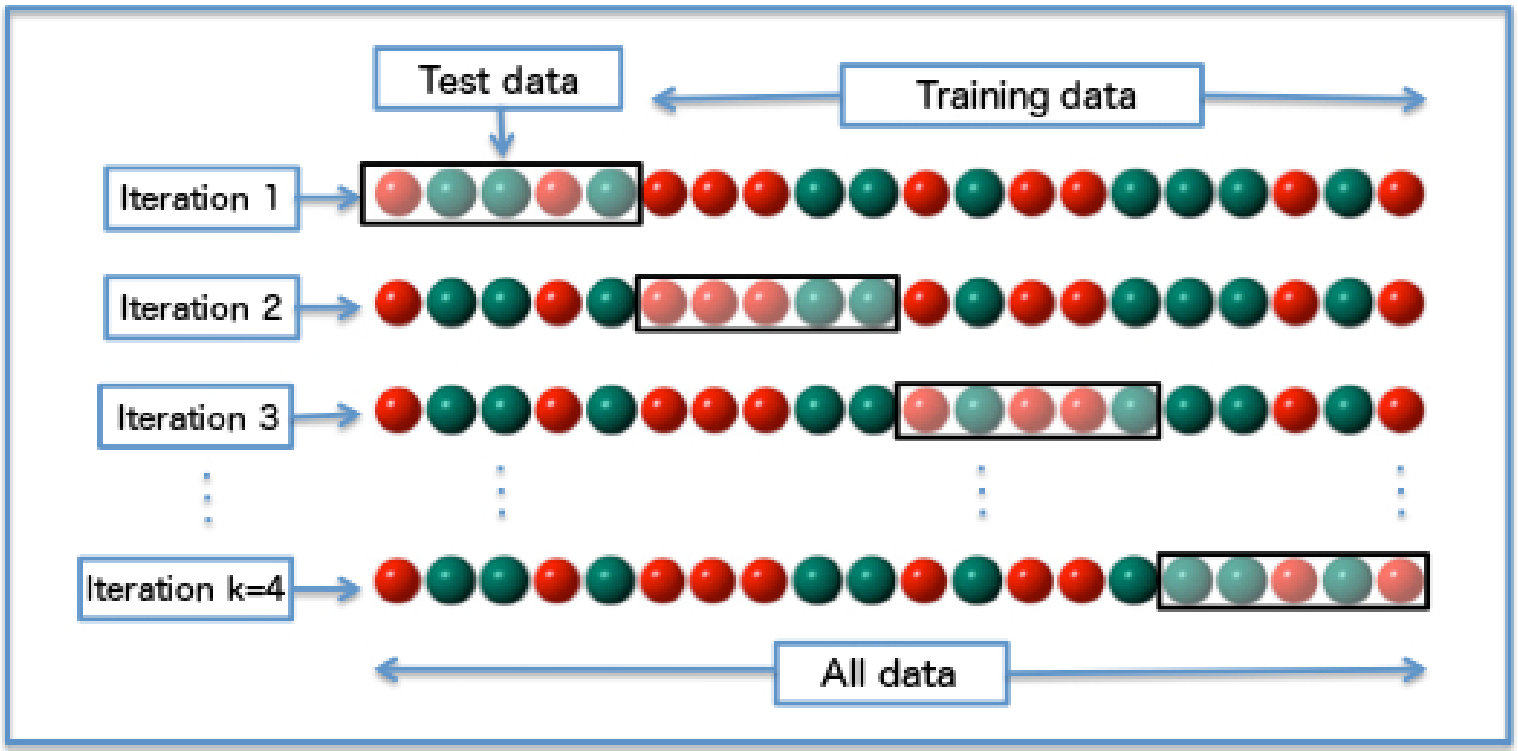

Ici, 4-fold cross-validation.

Apprentissage de modèles

1 - initialisation aléatoire du modèle

2 - Tant que(critère arret $==$ 0)

- Selection aléatoire d'un **batch** de données
- **Forward** : Passe avant du **batch** dans le modèle
- Calcul de l'erreur par rapport aux sorties attendues
- **Backward** : Rétropropagation du gradient de l'erreur en fonction des paramètres dans le modèle (mise à jour du modèle)
- Calcul critère arret

3 - Calcul de l'erreur sur un échantillon de données **qui n'ont JAMAIS été vues par le modèle pendant l'apprentissage !**

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features
- on définit quand même une perte (loss)

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features
- on définit quand même une perte (loss)

  Densité intra- et inter-clusters en clustering

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features
- on définit quand même une perte (loss)

  Densité intra- et inter-clusters en clustering

  Ou utiliser des données supervisées...

Apprentissage de modèles non-supervisés

Étant donné des exemples x_i, trouver un modèle h :

- but moins défini qu'en supervisé :
  - clustering : $h(x_i) = \hat{y}_i =$ cluster de x_i
  - détection d'anomalies : $y_i = 1$ si anomalie, 0 sinon
  - recommandations : $y_i =$ liste d'items $x_{k \neq i}$
  - réduction de dimensionnalité : $y_i = x_i$ projeté dans moins de features
- on définit quand même une perte (loss)

  Densité intra- et inter-clusters en clustering

  Ou utiliser des données supervisées... Pourcentage d'info perdue pour la réduction de dimentionnalité

Reproductibilité

- extrêmement importante pour compléter les analyses après les retours business
- ensemble de bonnes pratiques

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing
- de préférence utiliser des notebooks

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing
- de préférence utiliser des notebooks
- faire attention au random (utiliser des seeds)

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing
- de préférence utiliser des notebooks
- faire attention au random (utiliser des seeds)
- définir les datasets utilisés, dates comprises

Reproductibilité — bonnes pratiques

- garder une trace exacte du préprocessing
- de préférence utiliser des notebooks
- faire attention au random (utiliser des seeds)
- définir les datasets utilisés, dates comprises
- garder une trace de l'environnement

Méta-paramètres et Régularisation

Les méta-paramètres forment l'ensemble des prétraitements,la forme et les contraintes appliquées au modèle **AVANT** son apprentissage.

- Forme : Nombre de couches ?, de quelle taille ? ...
- L'algorithme d'optimisation (SGD, adaboost, adam,...)
- Méthodes de régularisation (norme des paramètres dans la loss, bruitage, dropout, ...)

Régularisation

$\approx$

empêcher le surapprentissage

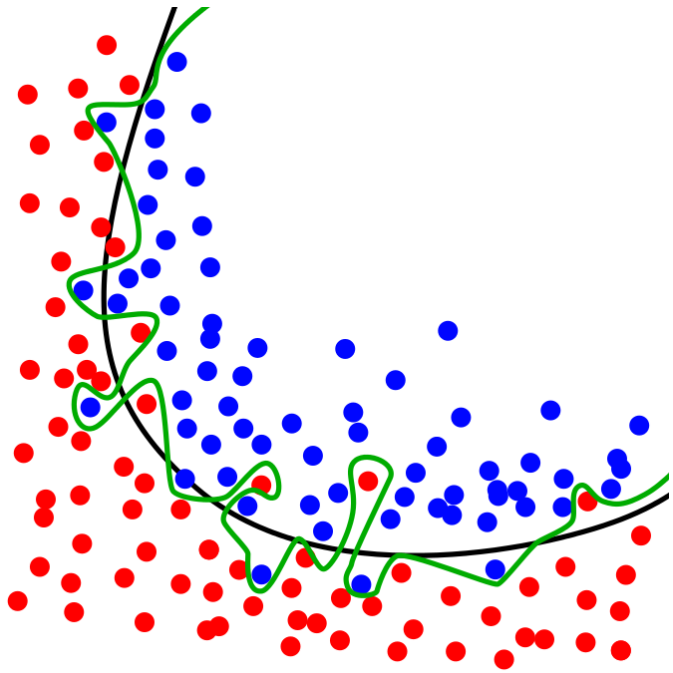

Avez-vous des questions ?

Machine Learning, méthodes et solutions

Exploration de données

Travaux Pratiques

Quelques fonctions utiles pour les Notebook dans Colaboratory

Après avoir ouvert le lien dans Colaboratory :

Fichier > Enregistrer une copie dans Drive...

Sinon vous ne pourrez pas éditer le notebook.

Travaux Pratiques

Exploration de données-TP

python-help
pandas-help
matplotlib-help
(Mais on n'oublie pas la doc ;-))