Machine Learning

De l'importance des données

Données à dimension fixe ou dimension variable?



Données à dimension fixe

- Image
- Texte (tf-idf: 50000 mots)
- ligne dans une table
- ...



Données à dimension variable

Données ancrées dans le temps. Séquence de données à dimension fixe

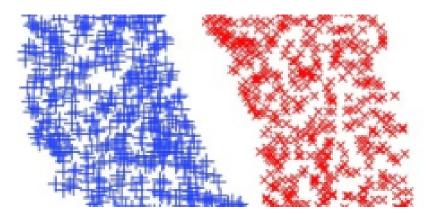
- Son
- Video
- Texte
- · ..



La collection de **données** est l'élément central du machine learning, bien plus que l'algorithme d'apprentissage lui-même!

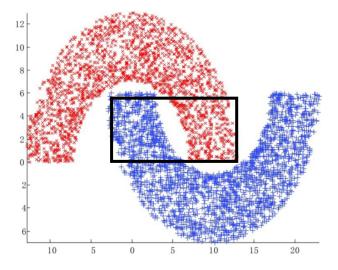


Quelle bonne méthode de séparation?





Quelle bonne méthode de séparation?

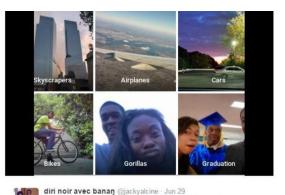




Il faut porter une attention toute particulière aux données :

- Qualité Vs Quantité?
- Représentation en vecteur?
- Données trouées, equilibrées,...?
- Éviter la fuite d'informations dégénérantes pour le modèle!









TWITTER