Réseaux de neurones adversaires

Objectifs

- Comprendre un nouveau paradigme d'apprentissage
- Découvrir ce que Yann LeCun a appelé la plus grande avancée en ML de cette décennie



Problème

- Un réseau de neurones apprend des fonctions complexes
- Toutefois sa métrique d'évaluation est très simple
- Elle dépend aussi du domaine
- Elle est « hardcodée » par l'humain
- \rightarrow Un apprentissage est toujours limité par une fonction de perte imparfaite.



Solution

Évaluer le réseau de neurones avec un autre réseau de neurones et non une fonction de perte. [?]

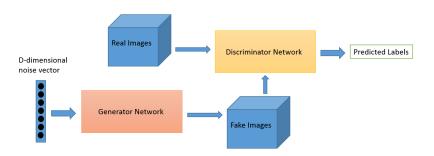


Les acteurs

- Un réseau générateur
- Un réseau discriminateur



Le jeu





Plus formellement

Minimax : entraîner les deux réseaux en maximisant des objectifs opposés.

- 1. Maximisation de l'efficacité du discriminateur sur les données
- 2. Maximisation des erreurs du discriminateur sur les données générées



Entraînement du discriminateur

$$\max_{D} \underset{x \sim \mathcal{P}_r}{\mathbb{E}} [\log(D(x))] + \underset{\tilde{x} \sim \mathcal{P}_g}{\mathbb{E}} [\log(1 - D(\tilde{x}))]$$



Entraînement du discriminateur

$$\max_{D} \underset{x \sim \mathcal{P}_r}{\mathbb{E}} [\log(D(x))] + \underset{\tilde{x} \sim \mathcal{P}_g}{\mathbb{E}} [\log(1 - D(\tilde{x}))]$$



Entraînement du discriminateur

$$\max_{D} \underset{x \sim \mathcal{P}_r}{\mathbb{E}} [\log(D(x))] + \underset{\tilde{x} \sim \mathcal{P}_g}{\mathbb{E}} [\log(1 - D(\tilde{x}))]$$

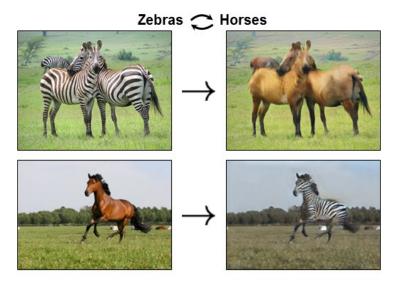


Entraînement du générateur

$$\min_{G} \underset{\tilde{\mathbf{x}} \sim \mathcal{P}_g}{\mathbb{E}} [\log(1 - D(\tilde{\mathbf{x}}))]$$



Convergence





Extension: Adversarially Learned Inference

Version adversaire du paradigme supervisé classique [?]

■ Discriminateur prédit si un décodeur a produit un couple (\tilde{x}, y) ou si un encodeur a produit un couple (x, \tilde{y})



Extension: Pix2Pix

Traductions d'image à image supervisée [?].



Extension: CycleGAN

Traductions d'image à image non supervisée [?].



