

# Mathématiques pour le machine learning

## Module 2

---

# Objectifs

---

- exprimer des transformations de données grâce à l'algèbre linéaire
- minimiser des fonctions analytiquement
- décrire l'incertain
- décrire des données

# Algèbre linéaire

---

- décrire des transformations simples sur un dataset entier avec des mécanismes adaptés
- comprendre les possibilités et les limites de ces transformations simples.

- algèbre linéaire = on se limite aux sommes pondérées des inputs.
- bonne nouvelle : énorme partie des opérations en machine learning

Python :

```
data = (1, 3)
```

Algèbre linéaire :

$$\mathbf{d} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

Python :

```
data = [(1, 3),  
        (2, 2),  
        (4, 2)]
```

Algèbre linéaire :

$$\mathbf{D} = \begin{bmatrix} 1 & 2 & 4 \\ 3 & 2 & 2 \end{bmatrix}$$



# Description des transformations linéaires

Python :


```
def weights(x, y):  
    return x * 2 + y / 2
```

Algèbre linéaire :

$$\mathbf{w} = \begin{bmatrix} 2 & \frac{1}{2} \end{bmatrix}$$


Transformation linéaire = somme pondérée.

# Application d'une transformation linéaire à un exemple



Bonne intuition à garder : Verser les colonnes (les exemples du dataset) dans les lignes (les opérations).

# Bonne intuition à garder



Bonne intuition à garder : Verser les colonnes (les exemples du dataset) dans les lignes (les opérations).

# Application d'une transformation linéaire à un exemple

Python :

```
data = (1, 3)
```

```
def weights(x, y):  
    return 2 * x + y / 2
```

```
res = weights(*data)
```

Algèbre linéaire :

$$f = \begin{bmatrix} 2 & \frac{1}{2} \end{bmatrix} \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$
$$= 2 \times 1 + \frac{1}{2} \times 3$$

# Application d'une transformation linéaire à un dataset

Python :

```
data = [(1, 3),  
        (2, 2),  
        (4, 2)]
```

```
def f(x, y):  
    return x * 2 + y / 2
```

```
res = [f(x, y)  
       for x, y  
       in data]
```

Algèbre linéaire :

$$\text{res} = \begin{bmatrix} 2 & \frac{1}{2} \end{bmatrix} \begin{bmatrix} 1 & 2 & 4 \\ 3 & 2 & 2 \end{bmatrix} \\ = \begin{bmatrix} 3,5 & 5 & 9 \end{bmatrix}$$

# Application de plusieurs transformations linéaires à un dataset

Python :

```
data = [(1, 3), (2, 2),  
        (4, 2)]
```

```
def f(x, y):  
    return x * 2 + y / 2
```


```
def g(x, y):  
    return x / 2 + y * 2
```

```
res = [[t(x, y) for x, y  
          in data]  
        for t in [f, g]]
```


Algèbre linéaire :

$$\begin{aligned} \text{res} &= \begin{bmatrix} 2 & \frac{1}{2} \\ \frac{1}{2} & 2 \end{bmatrix} \begin{bmatrix} 1 & 2 & 4 \\ 3 & 2 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 3,5 & 5 & 9 \\ 6,5 & 5 & 6 \end{bmatrix} \end{aligned}$$

## Bonne intuition à garder




# Bonne intuition à garder





$$\begin{bmatrix} 1 & 2 \\ 2 & 0 \end{bmatrix} \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix} = ?$$

# Exemple de transformation



$$\text{Bleu} = \text{Transformation} \times \text{Rouge}$$


$$= \begin{bmatrix} 1 & 2 \\ 2 & 0 \end{bmatrix} \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$= \begin{bmatrix} 0 & 2 & 3 & 1 \\ 0 & 0 & 2 & 2 \end{bmatrix}$$

	Taille
<b>D</b>	$(m, n)$
<b>W</b>	$(o, m)$
<b>WD</b>	$(o, n)$

→ dataset avec  $m$  features et  $n$  lignes transformé par  $o$  opérations donne dataset de  $o$  features et  $n$  lignes.


# Déterminant



Facteur de dilatation de la transformation (ratio aire bleue sur aire rouge).

Quel est le déterminant de cette transformation ? 4.


# Vecteur propre



Vecteur partant de l'origine qui conserve sa direction malgré la transformation.

Pouvez-vous en trouver un ?  $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$  par exemple.

# Valeur propre



Facteur par lequel un vecteur propre est redimensionné.

Quelle est la valeur propre de  $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$  ? 2.

# Analyse

---

Souvent besoin de minimiser une fonction en machine learning.

(trouver le  $x$  pour lequel  $f$  est minimale)

Vous souvenez-vous de comment l'on procède ?




Décider d'un  $x$  de départ puis suivre la pente jusqu'au minimum.

Pente = dérivée


→ Modifier itérativement  $x$  par un pas vers l'opposé de la dérivée.

# Pente positive



Opposé de la pente =  $-2$ . Avec un pas de 0,1, on passe de 1 à 0,8.

# Pente négative




Opposé de la pente = 2. Avec un pas de 0,1, on passe de  $-1$  à  $-0,8$ .

# Extension à plusieurs dimensions

- dérivée  $\rightarrow$  gradient
- identique sinon !

## Exemple en 2 dimensions



# Probabilités

---


- quantifier l'incertain
- support pour les statistiques

- la probabilité de l'événement  $X$  est notée  $P(X)$
- $P(X) \in [0, 1]$
- $P(X) = 0 \iff X$  est impossible
- $P(X) = 1 \iff X$  est certain
- $P(\neg X) = 1 - P(X)$



Décrit le comportement aléatoire d'un phénomène dépendant du hasard.

- $\sum_u P(X = u) = 1$  en discret
- $\int P(X) dX = 1$  en continu
- loi uniforme
- loi normale/gaussienne

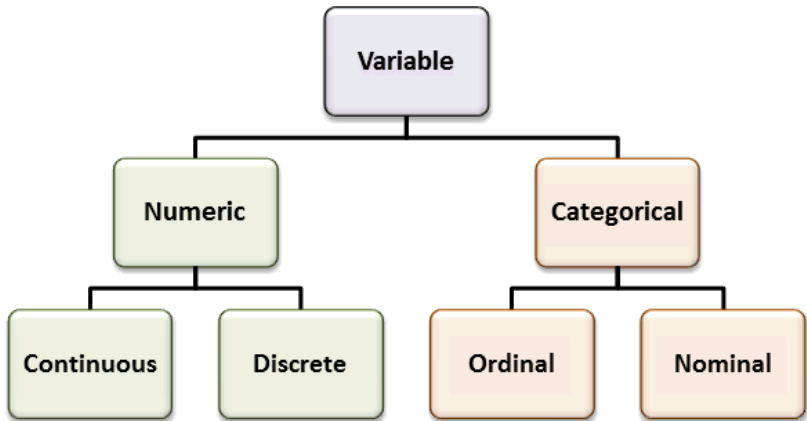


# Statistiques

---

- description et compréhension des données
- correction pour faciliter les traitements

# Types de variables



Pré-requis pour les mesures statistiques qui suivent (et la plupart du machine learning) :

- les données **doivent être issues d'une même loi**
- chaque échantillon doit être **indépendant** des autres
- pas évident en pratique ! Pourquoi ?

Mesure la dispersion d'une série statistique (ou d'une variable) :

$$V(X) = \mathbb{E} [(X - \mathbb{E}[X])^2]$$

Pour la calculer :


$$V(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Racine carrée de la variance

$$\sigma(X) = \sqrt{V(X)}$$

# Écart-type — règle des 68, 95 et 99,7

Pour les lois normales :






Les quartiles ( $Q_1$ ,  $Q_2$  et  $Q_3$ ) divisent les données en 4 intervalles contenant le même nombre d'observations.

Déclinable en quantile de taille arbitraire (décile, percentile).

Que veut dire être dans le 95<sup>e</sup> percentile ?

# Boxplot



Mesure la variabilité jointe de deux variables aléatoires :

$$V(X) = \mathbb{E} [(X - \mathbb{E}[X])(X - \mathbb{E}[X])]$$

$$\text{cov}(X, Y) = \mathbb{E} [(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

Pour la calculer :

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Covariance divisée par le produit des écart-types :


$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

Intérêt ? Pas d'unité.

Pour tester (et corriger) la normalité d'une distribution, on utilise deux mesures :


- l'asymétrie (*skew*)
- le kurtosis

# Asymétrie



$$\text{asym}(X) = \mathbb{E} \left[ \left( \frac{X - \bar{X}}{\sigma} \right)^3 \right]$$

# Kurtosis



$$\text{kurt}(X) = \mathbb{E} \left[ \left( \frac{X - \mu}{\sigma} \right)^4 \right]$$

Asymétrie et kurtosis peuvent se corriger avec la transformation de Box-Cox ou des transformations log.



## Quizz

---

- comment décrit-on un enregistrement ?
- comment décrit-on une transformation linéaire ?
- quel est le sens de la multiplication de matrices dans le contexte dataset/opérations ?

- intuitivement, qu'est-ce que nous apprend une dérivée ?
- à quelle valeur de la dérivée d'une fonction atteint-on un minimum ?
- si la dérivée est négative, dans quel sens faut-il faire évoluer  $x$  ?
- est-ce que la pas d'apprentissage impacte seulement les performances en temps de calcul ?

- quelle est la forme d'une gaussienne ?
- à combien somme une loi discrète ?

- quelle est l'hypothèse que l'on fait dans la plupart des approches de statistiques / machine learning ?
- que nous apprennent la variance et l'écart-type ?
- que nous apprennent la covariance et la corrélation ?
- comment peut-on savoir si une distribution est normale ?

## Conclusion

---

- algèbre linéaire → raisonner sur des opérations simples et les décrire efficacement
- minimiser une fonction continue → dérivée
- décrire l'incertain → probabilités
- caractériser une série de données → statistiques